

Alpamayo-R1-10B 추론 파이프 라인 분석

날짜

2026-03-04

작성자

노승우

Alpamayo VRAM Optimization Research

목차 (Table of Contents)

프로젝트 개요

7-Stage 파이프라인 요약

핵심 수치 요약

Vision Encoder

Patch Merger

VLM (Qwen3-VL-8B)

Expert Decoder

Action Space

Diffusion

단계별 문서

시각화 자료 목록

코드 참조 목록

소스 파일 위치

Alpamayo-R1-10B 추론 파이프라인 분석

프로젝트 개요

목적: Alpamayo-R1-10B 모델의 추론 파이프라인 전체 구조를 단계별로 분석하여, On-Demand Layering 최적화의 기초 자료로 활용

대상 모델: NVIDIA Alpamayo-R1-10B — 자율주행용 Vision-Language-Action(VLA) 모델 - Vision Encoder: Qwen3-VL 기반 ViT (27 레이어, hidden=1152) - VLM 백본: Qwen3-VL-8B (36 레이어, hidden=4096) - Expert Decoder: 경량 Transformer (hidden=2048) - 액션 생성: Flow Matching 기반 Diffusion (10 Euler 스텝)

7-Stage 파이프라인 요약

단계	이름	입력	출력	핵심 연산
Stage 1	Patch Embedding	$(B, 3, T, H, W)$ 이미지 텐서	$(N_patches, 1152)$	Conv3d + 3D RoPE
Stage 2	Vision Transformer	$(N_patches, 1152)$	$(N_patches, 1152)$	27× LayerNorm→MHA→MLP
Stage 3	Patch Merger	$(N_patches, 1152)$	$(N_patches/4, 4096)$	2×2 Concat → Linear(4608→4096)
Stage 4	VLM Prefill	$(N_vis + N_text, 4096)$	$(N_seq, 4096)$	36× GQA Decoder Layer
Stage 5	VLM Decode	$(1, 4096) + KV$ Cache	$(N_reason, 4096)$	Autoregressive 생성
Stage 6	Expert Decode	$(N_reason, 4096) \rightarrow (N_act, 2048)$	$(N_act, 2048)$	Action projection + Decoder
Stage 7	Diffusion	Noisy waypoints	64 waypoints (accel, curvature)	Flow Matching, 10 Euler 스텝

핵심 수치 요약

Vision Encoder

항목	값
Hidden dimension	1152
Attention heads	16
Head dimension	72 (= 1152 / 16)
Transformer 레이어 수	27
Patch 크기	16×16 (spatial), 2-frame (temporal)
Conv3d 커널	(2, 16, 16), stride=(2, 16, 16)
입력 채널	3 (RGB)
MLP 확장 비율	4304 / 1152 $\approx$ 3.73
활성화 함수	SiLU

Patch Merger

항목	값
공간 병합 크기	2×2
입력 차원	1152 × 4 = 4608
출력 차원	4096
활성화 함수	GELU

VLM (Qwen3-VL-8B)

항목	값
Hidden dimension	4096
Intermediate dimension	12288
레이어 수	36
Attention heads (Q)	32
KV heads (GQA)	8
Head dimension	128

Expert Decoder

항목	값
Hidden dimension	2048
Intermediate dimension	8256
Attention heads	16
Head dimension	128

Action Space

항목	값
Waypoint 수	64
액션 차원	2 (accel, curvature)
시간 간격 (dt)	0.1 s
총 예측 수평선	6.4 s

Diffusion

항목	값
방식	Flow Matching
Euler 스텝 수	10
노이즈 스케줄	Linear (t: 0→1)

단계별 문서

문서	내용
01_patch_embedding.md	Conv3d 패치 임베딩 + 3D Rotary Embedding
02_vision_transformer.md	27-Layer Vision Transformer 블록 구조
03_patch_merger.md	2×2 패치 병합 + VLM 차원 투영

시각화 자료 목록

파일	내용
figures/ vision_encoder_detail.png	Vision Encoder 전체 구조 (PatchEmbed → 27 Blocks → Merger)

코드 참조 목록

파일	내용
code_references/ vision_encoder.md	<code>Qwen3VLVisionPatchEmbed</code> , <code>Qwen3VLVisionBlock</code> , <code>Qwen3VLVisionPatchMerger</code> 발췌
code_references/ vlm_model.md	VLM (Qwen3VLTextModel) 구조 발췌
code_references/ action_in_proj.md	Action input projection 발췌
code_references/ action_space.md	Unicycle action space 발췌
code_references/ diffusion.md	Flow Matching diffusion 발췌
code_references/ inference.md	추론 전체 흐름 발췌

소스 파일 위치

컴포넌트	경로
Vision Encoder	<code>alpamayo/ar1_venv/lib/python3.12/site-packages/transformers/models/ qwen3_vl/modeling_qwen3_vl.py</code>
VLM 모델	<code>alpamayo/src/alpamayo_r1/models/alpamayo_r1.py</code>
베이스 모델	<code>alpamayo/src/alpamayo_r1/models/base_model.py</code>
Diffusion	<code>alpamayo/src/alpamayo_r1/diffusion/flow_matching.py</code>
Action Space	<code>alpamayo/src/alpamayo_r1/action_space/unicycle_accel_curvature.py</code>
Action Projection	<code>alpamayo/src/alpamayo_r1/models/action_in_proj.py</code>
Config	<code>alpamayo/src/alpamayo_r1/config.py</code>