

목차 (Table of Contents)

1. 개요

연구 목표

핵심 가설

오늘의 목표

2. 실험 환경

하드웨어

소프트웨어

모델

3. 실험 1: FP16 베이스라인 측정

목적

방법

결과

4. 실험 2: 메모리 접근 패턴 프로파일링

목적

방법

결과

분석

시각화

5. 실험 3: 4-bit 양자화 모델 프로파일링

목적

방법

결과

시각화

6. FP16 vs 4-bit 비교 분석

핵심 관찰

시각화

7. 결론 및 인사이트

8. 향후 계획

참고

실험 리포트 — 2026-02-25

Alpamayo-R1-10B VRAM 최적화 연구: 환경 구축, 베이스라인 측정, 병목 분석, 경량화 비교

1. 개요

연구 목표

NVIDIA Alpamayo-R1-10B는 자율주행 VLA(Vision-Language-Action) 모델로, 공식 요구사항은 24GB VRAM이다. 본 연구는 이 모델을 12GB VRAM 환경(RTX 3080 Ti)에서 효율적으로 구동하는 방법을 탐색한다.

핵심 가설

CUDA Unified Memory를 통한 CPU-GPU 메모리 스와핑 시, 이론 대역폭(PCIe Gen3 x16, ~16GB/s) 대비 실제 성능이 수백 배 느린 **구조적 비효율**이 존재한다.

오늘의 목표

1. 실험 환경 구축 (WSL2 + Alpamayo 설치)
 2. FP16 베이스라인 측정
 3. 메모리 접근 패턴 프로파일링 및 병목 분석
 4. 4-bit 양자화 모델 비교 실험
-

2. 실험 환경

하드웨어

항목	스펙
GPU	NVIDIA RTX 3080 Ti (12GB VRAM)
CPU	Intel i7-10700K
RAM	16GB
PCIe	Gen 3 x16 (~16GB/s 이론 대역폭)

소프트웨어

항목	버전
OS	WSL2 (Ubuntu on Windows)
Python	3.12.12
PyTorch	2.8.0+cu128
CUDA (드라이버)	12.6
패키지 매니저	uv 0.10.6

모델

모델	정밀도	크기	출처
nvidia/Alpamayo-R1-10B	FP16 (bfloat16)	~20GB	HuggingFace (공식)
dwko/Alpamayo-R1-10B-4bit	BitsAndBytes fp4	~5GB	HuggingFace (커뮤니티)

3. 실험 1: FP16 베이스라인 측정

목적

12GB VRAM에서 FP16 원본 모델의 추론 성능과 메모리 사용 패턴을 측정한다.

방법

- 더미 입력 데이터 사용: 4카메라 x 4프레임 x 320 x 576 해상도
- bfloat16 정밀도로 모델 로딩
- CUDA Unified Memory를 통한 자동 스와핑 (OOM 회피)
- 스크립트: `experiments/test_dummy_inference.py`

결과

지표	측정값
모델 로드 시간	54.2초
VRAM 할당량	20.65GB
추론 시간	280.5초
Peak VRAM	21.52GB

- Unified Memory를 통해 OOM 없이 자동 스와핑이 발생하였다.
- 이론 스왑 시간(~0.6초, 약 10GB / 16GB/s) 대비 실제 추론 시간(280초)은 약 **470배 차이**를 보였다.

4. 실험 2: 메모리 접근 패턴 프로파일링

목적

280초 추론 시간의 내부 구성을 시간 분해하고, VRAM 스와핑 패턴을 분석하여 병목 원인을 규명한다.

방법

- 5단계 시간 분해 (Phase 1~5)

- 0.5초 간격 VRAM 모니터링 (총 704 샘플)
- 스크립트: `experiments/profile_memory.py`
- 데이터: `experiments/memory_profile.csv`

결과



Phase	설명	소요 시간	비율
Phase 1	더미 데이터 생성	0.08초	0.0%
Phase 2	CPU 모델 로드	13.51초	3.9%
Phase 3	.to("cuda") 전송	56.86초	16.3%
Phase 4	입력 데이터 준비	4.73초	1.4%
Phase 5	VLM 추론	273.79초	78.5%
합계		348.97초	100%


분석

- VLM 추론(Phase 5)이 전체의 78.5% 를 차지한다.
- 토큰당 생성 시간: ~1.07초 (정상 범위 30~50ms 대비 **20~30배 느림**).
- Phase 3(.to cuda)에서 20.65GB를 12GB 물리 VRAM에 올리면서 Unified Memory 스와핑이 시작된다.
- 핵심 병목: 매 토큰 생성 시 **무작위 페이지 스왑**이 반복 발생하여, PCIe 대역폭을 효율적으로 활용하지 못한다.
- Peak VRAM 21.52GB는 물리 VRAM(12GB)의 1.8배에 해당한다.

시각화

- VRAM 시계열: `../experiments/figures/memory_timeline.png`
- Phase별 시간 분해: `../experiments/figures/phase_breakdown.png`
- 이론 스왑 vs 실제 추론: `../experiments/figures/theory_vs_actual.png`





5. 실험 3: 4-bit 양자화 모델 프로파일링

목적

BitsAndBytes fp4 양자화 모델이 12GB VRAM 이내에서 동작하는지 확인하고, FP16 대비 성능을 비교한다.

방법

- dwko/Alpamayo-R1-10B-4bit (BitsAndBytes fp4 양자화) 사용
- 동일 더미 입력 데이터 (4카메라 x 4프레임 x 320 x 576)
- 스크립트: `experiments/profile_memory_4bit.py`
- 데이터: `experiments/memory_profile_4bit.csv`

결과


Phase	설명	소요 시간	비율
Phase 2+3	모델 로드 (초회 HF 캐싱 포함)	158.80초	94.5%
Phase 4	입력 데이터 준비	4.31초	2.6%
Phase 5	VLM 추론	4.91초	2.9%
합계		168.11초	100%


지표	측정값
Peak VRAM	8.87GB
VRAM 여유	3.13GB (12GB 이내)

- 4-bit 모델은 12GB VRAM 이내에서 **스와핑 없이** 완전히 동작한다.
- VLM 추론이 4.91초로 FP16(273.79초) 대비 극적으로 개선되었다.
- 현재 병목은 모델 로드 시간(158.80초)이며, 이는 초회 HuggingFace 캐싱이 포함된 수치이다.

시각화

- VRAM 시계열: [../experiments/figures/memory_timeline_4bit.png](#)
- Phase별 시간 분해: [../experiments/figures/phase_breakdown_4bit.png](#)






6. FP16 vs 4-bit 비교 분석

지표	FP16	4-bit	변화
VLM 추론 시간	273.79초	4.91초	-98% (55.8x 개선)
Peak VRAM	21.52GB	8.87GB	-59%
모델 로드 시간	111.06초	158.80초	+42%
총 소요 시간	348.97초	168.11초	-52%
VRAM 스와핑	발생 (Unified Memory)	없음	-
12GB VRAM 적합성	부적합 (21.52GB 필요)	적합 (8.87GB)	-

핵심 관찰

- FP16의 추론 시간 273초는 모델 연산이 아닌 **메모리 스왑 오버헤드**가 절대적 원인이다.
- 4-bit 양자화로 모델 크기를 12GB VRAM 이내로 줄이면 스와핑이 제거되어 추론이 55.8배 빨라진다.
- 4-bit의 모델 로드 시간(158초)은 FP16(111초)보다 42% 길지만, 이는 초회 캐싱 비용이 포함된 수치이다.

시각화



7. 결론 및 인사이트

- FP16 모델의 273초 추론 시간은 연산이 아닌 메모리 스왑 오버헤드이다.** - 이론 스왑 시간 (0.6초) 대비 실제(273초)의 ~456배 격차는, 매 토큰 생성 시 발생하는 무작위 페이지 스왑 패턴이 원인이다. - Unified Memory의 페이지 단위 스와핑은 순차적 대량 전송이 아닌, 산발적 소량 전송을 반복하여 PCIe 대역폭을 극히 비효율적으로 사용한다.
- 4-bit 양자화로 12GB VRAM 이내 동작이 가능하다.** - Peak VRAM 8.87GB로 12GB 물리 VRAM 이내에서 완전 동작한다. - VLM 추론이 4.91초로 FP16 대비 55.8배 개선되었다.
- 현재 병목은 모델 로드 시간이다.** - 4-bit 모델의 로드 시간 158초는 전체의 94.5%를 차지한다. - 초회 HuggingFace 캐싱이 포함되어 있으므로, 캐싱 이후 재실행 시 개선이 예상된다.
- 이론 스왑 시간(0.6초) vs 실제(273초) 격차의 원인은 무작위 페이지 스왑 패턴이다.** - Unified Memory는 필요한 페이지를 요청 시점에 개별 전송하므로, 연속 메모리 블록의 일괄 전송 대비 극히 비효율적이다. - 이는 `device_map="auto"` 등을 통한 계획적 레이어 분배로 개선 가능성이 있다.

8. 향후 계획

순서	실험	목적
1	<code>device_map="auto"</code> 레이어 분배 테스트	계획적 offloading vs 무작위 스왑 성능 비교
2	4-bit 모델 캐싱 후 재실행	순수 모델 로드 시간 측정 (HF 캐싱 비용 제거)
3	FP16 vs 4-bit 출력 궤적 정확도 비교	양자화로 인한 정확도 손실 정량화
4	KV cache 최적화 탐색	추론 중 메모리 효율 추가 개선

참고

- 연구 방향성: [research.md](#)
- 설치 가이드: [alpamayo-setup-guide.md](#)
- 실험 상세: [experiments/README.md](#)
- 작업 로그: [2026-02-25.md](#)