

목차 (Table of Contents)

1. 연구 목표
 2. 핵심 질문
 3. 관심 영역
 4. 기술 스택 / 도구
 5. 실험 및 아이디어
 - 5-1. 미완료 작업 (다음 세션 진행)
 6. 참고 자료
 7. 의사결정 로그
- 메모

AI / Machine Learning 연구 방향성

이 문서는 작업과 대화를 통해 점진적으로 발전시켜 나가는 살아있는 문서입니다. 마지막 업데이트: 2026-02-25

1. 연구 목표

- NVIDIA Alpamayo-R1-10B 모델(24GB VRAM 요구)을 12~16GB VRAM 환경에서 효율적으로 구동하는 방법 연구

2. 핵심 질문

- CPU-GPU 메모리 스와핑 시 이론 대역폭 대비 100~200배 느린 원인은?
- **메모:** 이론 스왑 0.6초 vs 실제 280초 → ~470배 차이 확인. 4-bit(8.87GB, 스왑 없음)에서 추론 4.51초 → FP16의 273초가 전부 스왑 오버헤드임을 증명
- 3단계 파이프라인(비전 인코더 → VLM 8.2B → Diffusion 디코더 2.3B) 구조에서 스와핑 최적화 포인트는?
- 12GB VRAM으로 실용적 속도(프레임당 초 단위)를 달성할 수 있는가?

3. 관심 영역

- [x] GPU 메모리 오프로딩 최적화
- [x] 모델 양자화 (INT8, INT4) (**X — 배제: 모델 정확도 저하 방식**)
- [x] 파이프라인 단계별 메모리 스케줄링
- [x] PCIe 대역폭 활용 극대화 (프리페칭, 비동기 전송)

4. 기술 스택 / 도구

도구	용도	비고
RTX 3080 Ti 12GB	GPU 연산	VRAM 12GB
i7-10700K	CPU 연산 / 오프로딩 호스트	
RAM 16GB	CPU 메모리 (오프로딩 대상)	
PCIe Gen 3 x16	CPU-GPU 데이터 전송	~16GB/s 이론 대역폭
CUDA 12.6	GPU 프로그래밍	
WSL2	개발 환경	Linux on Windows

5. 실험 및 아이디어

#	아이디어	상태	메모
1	Alpamayo 기본 실행 및 베이스라인 측정	완료	Peak VRAM 21.52GB, 추론 280.5초, Unified Memory 스와핑
2	메모리 접근 패턴 프로파일링	완료	VLM 추론 78.5%, 토큰당 1.07초, 20~30배 느림
3	device_map=auto 레이어 분배 테스트	예정	계획적 offloading vs 무작위 스왑 비교
4	4-bit 양자화 모델(BnB fp4) 프로파일링 (X — 배제: 모델 정확도 저하 방식)	완료	Peak 8.87GB, 추론 4.51초, FP16 대비 55.8배 빠름
5	On-Demand Layering (device_map)	완료	device_map 추론 실패, VLM 68.5% 병목, 커스텀 구현 필요
6	메모리 파이프라이닝	완료	PCIe H2D 7.77/D2H 11.8 GB/s, 비동기 프리페치 1.53x, VLM 레이어별 스왑 필수
7	CPU-GPU 스왑 최적화	완료	WSL2 pageable D2H 4.5x 느림, pinned 필수, 최적 청크 2-8MB
8	창의적 접근 (7개 아이디어)	완료	Top3: 하이브리드 양자화 (X — 배제), 디퓨전 스텝 축소, 동적 해상도 (X — 배제)

5-1. 미완료 작업 (다음 세션 진행)

#	작업	우선 순위	예상 소요	메모
1	권장 전략 조합 실측 (하이브리드 양자화 (X — 배제) + 디퓨전 5스텝 + 동적 해상도 (X — 배제))	높음	2-3시간	예상 ~6.5GB Peak, ~3.2초 추론 검증
2	4-bit 모델 캐싱 후 재실행 (순수 로드 시간 측정)	높음	30분	158초 중 HF 캐싱 제외한 실제 로드 시간
3	Pinned memory 기반 실제 Alpamayo 추론	높음	1-2시간	방향 3 발견(pinned 4.8x 빠름)을 실제 모델에 적용
4	커스텀 레이어 배치 구현 (device_map 수동)	중간	2-3시간	auto 실패 → 수동 레이어 GPU/CPU 배치로 재시도
5	VLM 레이어 pruning 실험 (36→18 레이어) (X — 배제: 가지치기 - 모델 정확도 저하 방식)	중간	1-2시간	출력 궤적 품질 비교 필요
6	FP16 vs 4-bit 출력 궤적 정확도 비교 (X — 배제: 양자화 정확도 비교 - 양자화 자체가 배제됨)	중간	1시간	양자화로 인한 품질 저하 정량 측정
7	Speculative decoding PoC	낮음	3-4시간	커스텀 토큰/KV cache 공유 문제 해결 필요

6. 참고 자료

-

7. 의사결정 로그

날짜	결정 사항	이유
2026-02-25	연구 주제 확정 — Alpamayo VRAM 최적화	이론 vs 실제 스왑 성능 차이가 구조적 비효율 가설의 근거
2026-02-25	베이스라인 측정 완료	Peak VRAM 21.52GB, 추론 280.5초, Unified Memory 스와핑 확인
2026-02-25	4-bit 양자화 실험 완료	FP16 추론 273초의 원인이 스왑 오버헤드임을 4-bit 실험으로 확인. Peak 8.87GB로 12GB 이내 동작
2026-02-25	4개 연구 방향 탐색 완료	On-Demand Layering 제한적, 스왑 최적화 pinned 필수, 하이브리드 양자화 최유망

메모

자유롭게 기록하는 공간