

연구 방향 4: 창의적이고 새로운 연구 주제 탐색 및 가능성 검증 보고서

날짜

2026-02-25

작성자

노승우

Alpamayo VRAM Optimization Research

목차 (Table of Contents)

0. 모델 구조 정밀 분석 (실험을 통한 확인)

Alpamayo-R1-10B 정확한 구조

핵심 발견사항 (이전 연구 보정)

1. 하이브리드 양자화 (Mixed Precision Offloading) (X — 배제: 모델 정확도 저하 방식)

1.1 이론적 분석

1.2 양자화 시나리오별 메모리 (VLM만, 실측)

1.3 양자화 오차 실측

1.4 모듈별 오프로딩 + 양자화 조합 전략 (실측)

1.5 평가

2. KV Cache 압축/오프로딩

2.1 이론적 분석

2.2 토큰 수에 따른 KV Cache 크기 (GQA 보정)

2.3 KV Cache 압축 기법 실측 (양자화 기반 항목은 X — 배제: 모델 정확도 저하 방식)

2.4 KV Cache CPU 오프로딩 벤치마크

2.5 평가

3. Speculative Decoding + 소형 모델 활용

3.1 적용 가능 단계 분석

3.2 Draft 모델 후보 벤치마크

3.3 이론적 속도 향상

3.4 Alpamayo 고유 도전과제

3.5 평가

4. 레이어 가지치기 (Layer Pruning) (X — 배제: 모델 정확도 저하 방식)

4.1 레이어 구조 분석

4.2 가지치기 시나리오 (실측)

4.3 레이어 중요도 패턴

4.4 레이어 스킵 속도 벤치마크 (시뮬레이션)

4.5 평가

5. 동적 해상도 조절 (X — 배제: 모델 정확도 저하 방식)

5.1 Qwen3-VL Vision 토큰 분석

5.2 해상도 변경 시 메모리 영향

- 5.3 Attention 속도 벤치마크 (시퀀스 길이별)
- 5.4 트레이드오프 분석
- 5.5 Vision 처리 속도 실측
- 5.6 평가
- 6. 디퓨전 스텝 축소 + Expert 경량화 (창의적 아이디어 1)
 - 6.1 배경
 - 6.2 스텝 수별 시간 실측 (시뮬레이션)
 - 6.3 Expert 모델 경량화 옵션
 - 6.4 Consistency Distillation 가능성
 - 6.5 파이프라인 시간 분석 (4-bit 기준)
 - 6.6 평가
- 7. Token Merging + Chunked Prefill (창의적 아이디어 2)
 - 7.1 활성화 메모리 분석
 - 7.2 Chunked Prefill 벤치마크
 - 7.3 Token Merging (ToMe) 적용 가능성
 - 7.4 Selective Recomputation 전략
 - 7.5 평가
- 8. 종합 평가 매트릭스
 - 8.1 아이디어별 평가 요약
 - 8.2 종합 우선순위 (가능성 x 효과 x 구현용이성)
- 9. 최종 권장 연구 방향 Top 3
 - Top 1: 하이브리드 양자화 확장 (Attn-INT8 + FFN-INT4) (X — 배제: 모델 정확도 저하 방식)
 - Top 2: 디퓨전 스텝 축소 (10 → 5)
 - Top 3: 동적 해상도 + min_pixels 최적화 (X — 배제: 모델 정확도 저하 방식)
- 10. 세 방향의 조합 최적화 시나리오
- 부록: 실험 스크립트 및 결과 파일
 - 시각화

연구 방향 4: 창의적이고 새로운 연구 주제 탐색 및 가능성 검증 보고서

실험일: 2026-02-25 환경: NVIDIA GeForce RTX 3080 Ti (12 GB VRAM), WSL2 (Kernel 6.6.87.1) 모델: nvidia/Alpamayo-R1-10B (BF16 = ~20.88 GB) Python: `/home/seungwoo/workspace/alpamayo/ar1_venv/bin/python`

0. 모델 구조 정밀 분석 (실험을 통한 확인)

Alpamayo-R1-10B 정확한 구조

모듈	파라미터	크기 (BF16)	핵심 구성
Vision Encoder (SigLIP)	~0.58B	1.15 GB	hidden=1152, patch=14
VLM (Qwen3-VL-8B)	~8.2B	15.17 GB	36 layers, hidden=4096, intermediate=12288, 32 attn heads, 8 KV heads (GQA)
Expert (경량 Transformer)	~0.8B	~1.6 GB	hidden=2048, intermediate=8256, 16 attn heads
Action Projections + Diffusion	~1.5B	~2.96 GB	action_in_proj (MLP), action_out_proj, FlowMatching
합계	~11.08B	~20.88 GB	-

핵심 발견사항 (이전 연구 보정)

- VLM은 GQA 사용 (num_kv_heads=8, num_attention_heads=32): KV cache가 full MHA 대비 4배 작음

2. **Expert 모델은 VLM보다 작음**: hidden=2048 (VLM의 절반), 별도 구성
3. **VLM intermediate_size=12288** (Qwen3-VL-8B 기본값): 이전 분석의 22016은 Alpamayo의 오버라이드된 config에서 읽은 값
4. **traj_vocab_size=4000** (768이 아님), tokens_per_future_traj=128

1. 하이브리드 양자화 (Mixed Precision Offloading) (X — 배제: 모델 정확도 저하 방식)

1.1 이론적 분석

Alpamayo VLM의 각 레이어는 **Attention 파라미터(~20%)**와 **FFN 파라미터(~80%)**로 구성된다. FFN이 지배적이므로, FFN에 더 공격적인 양자화를 적용하면 전체 메모리를 효과적으로 줄일 수 있다.

실험으로 확인된 레이어 구성 (Alpamayo config 기준): - Attention (Q/K/V/O): 67.1M params/layer (19.9%) - FFN (gate/up/down): 270.5M params/layer (80.1%) - 총: 337.6M params/layer

1.2 양자화 시나리오별 메모리 (VLM만, 실측)

시나리오	VLM 크기	12GB 이내	비고
Full FP16 (baseline)	20.13 GB	불가	-
Full INT8	10.06 GB	가능	KV cache + activation 포함 시 초과 가능
Attn-INT8 + FFN-INT4	6.03 GB	가능	FFN이 80%이므로 INT4 효과 큼
Attn-INT4 + FFN-INT8	9.06 GB	가능	Attention INT4는 품질 우려
Full INT4	5.03 GB	가능	기존 4-bit 결과 (8.87GB peak) 과 일치

1.3 양자화 오차 실측

가중치 유형	INT8 상대오차	INT4 상대오차	INT4/INT8 비율
Attention (4096x4096)	0.94%	12.56%	13.4x
FFN (4096x14336)	1.01%	12.56%	12.4x


INT4는 INT8 대비 약 13배 높은 양자화 오차를 보인다. Attention 가중치는 정확도에 민감하므로 INT8, FFN은 더 관대하므로 INT4 적용이 합리적.


1.4 모듈별 오프로딩 + 양자화 조합 전략 (실측)

전략	Peak VRAM	12GB	설명
VLM-INT4 + Others-FP16-Offload	5.56 GB	OK	VLM만 INT4, 나머지 필요 시 전송
All-INT4	6.22 GB	OK	전체 INT4
VLM-INT4 + Expert-INT8	7.07 GB	OK	Expert는 INT8 (정확도 유지)
VLM-Hybrid + Offload	8.17 GB	OK	Attention INT4 + FFN INT8
All-on-GPU (VLM-INT4)	11.00 GB	OK (간신히)	VLM INT4 + Vision FP16 + Expert FP16

1.5 평가

- **가능성: 높음** - 이미 4-bit 전체 양자화가 동작 확인됨 (Peak 8.87GB)
- **구현 난이도: 보통** - bitsandbytes, GPTQ, AWQ 등 도구 활용
- **예상 효과:** VRAM ~60-75% 절감 (FP16 대비), 추론 속도 55x 개선 (기존 결과)
- **Attn-INT8 + FFN-INT4 하이브리드:** 추가 ~1GB 절감 + 정확도 개선 가능





2. KV Cache 압축/오프로딩

2.1 이론적 분석

Qwen3-VL-8B의 KV cache 구성: - 36 layers, **8 KV heads (GQA)**, head_dim=128 - **KV per token (all layers):** $2 \times 8 \times 128 \times 2(\text{BF16}) \times 36 = 147,456 \text{ bytes} \approx 144 \text{ KB/token}$

주의: 실험에서 config 로드 시 Alpamayo의 오버라이드 config를 읽어 num_kv_heads=32로 표시되었으나, 실제 Qwen3-VL-8B는 **GQA(8 KV heads)**를 사용한다. 따라서 실제 KV cache는 4배 작다.

2.2 토큰 수에 따른 KV Cache 크기 (GQA 보정)

토큰 수	KV Cache (GQA, 8 heads)	KV Cache (Full MHA, 32 heads)
1,024	128 MB	512 MB
2,048	256 MB	1,024 MB
4,096	512 MB	2,048 MB
4,470 (Alpamayo 추정)	559 MB	2,235 MB

GQA 덕분에 KV cache는 ~559 MB (추정 최대 4470 토큰). 이는 전체 VRAM의 약 4.7%에 불과하다.

2.3 KV Cache 압축 기법 실측 (양자화 기반 항목은 X — 배제: 모델 정확도 저하 방식)


압축 기법	압축률	상대 오차 (K)	메모리 절감
INT8 양자화	1.94x	2.92%	48.4%
INT4 group 양자화 (g=32)	3.20x	25.8%	68.8%
Token Eviction (50%)	2.00x	가변	50.0%
Token Eviction (25%)	4.00x	가변	75.0%

2.4 KV Cache CPU 오프로딩 벤치마크

- 36 layers x 1024 tokens 기준 (72 MB):
- Sequential 전송: **9.86 ms** (유효 대역폭 7.13 GB/s)
- 비동기 파이프라인: 33.09 ms (오버헤드 발생)

2.5 평가

- **가능성: 중간-높음** - GQA로 인해 KV cache 자체가 작아 절감 효과 제한적
- **구현 난이도: 보통** - 기존 라이브러리(vLLM, TGI) 참조 가능
- **예상 효과:** GQA 기준 KV cache ~559 MB → INT8로 ~288 MB (271 MB 절감)
- **권장:** KV cache가 전체 VRAM의 5% 미만이므로, 다른 최적화와 조합 시 보조적 역할



3. Speculative Decoding + 소형 모델 활용

3.1 적용 가능 단계 분석

Alpamayo 파이프라인 3단계 중 **VLM Autoregressive Generation**만 해당: 1. Vision Encoding: 비자기회귀 → 비해당 2. **VLM CoT 생성 (최대 256 토큰): 적용 가능** 3. Expert + Diffusion (10 Euler steps): 비해당

3.2 Draft 모델 후보 벤치마크

모델	Layers	Forward Time	VRAM	비고
Qwen3-VL-8B (full)	36	14.55 ms	296 MB	Baseline
Half layers (18)	18	7.28 ms	296 MB	Layer-skipping
Quarter layers (9)	9	3.59 ms	296 MB	Layer-skipping
Qwen3-VL-2B	28	2.65 ms	49 MB	별도 모델

3.3 이론적 속도 향상

최적 조건 (gamma=8, alpha=0.9, 2B draft): - FP16 target: **5.95x** speedup - INT4 target: **2.35x** speedup

INT4 모델의 경우 기본 속도가 이미 빠르므로 speculative decoding 이점이 줄어든다.

3.4 Alpamayo 고유 도전과제

도전과제	심각도	설명
커스텀 토큰 (4000개 traj + 특수 토큰)	높음	Draft 모델에도 동일 vocab 필요
KV cache → Expert 공유	높음	VLM KV cache가 Expert의 past_key_values로 사용됨
12GB VRAM 제약	높음	Target + Draft 동시 로드 어려움
ExpertLogitsProcessor	중간	traj 토큰 마스킹 동기화 필요

3.5 평가

- **가능성: 낮음-중간** - 도전과제 다수, VLM 생성이 전체의 ~60%이지만 구현 복잡
- **구현 난이도: 어려움** - 커스텀 토큰, KV cache 공유 등 비표준 문제
- **예상 효과:** VLM 단계 2-6x 가속 (전체 1.5-3x), 메모리 중립 (layer-skipping) 또는 증가 (별도 모델)
- **권장 접근: Layer-skipping** (추가 메모리 불필요, vocab 공유) → 별도 연구 필요

4. 레이어 가지치기 (Layer Pruning) (X — 배제: 모델 정확도 저하 방식)

4.1 레이어 구조 분석

VLM 1개 레이어: - Attention: 67.1M params (19.9%) → **128 MB** (FP16) - FFN: 270.5M params (80.1%) → **516 MB** (FP16) - 합계: 337.6M params → **644 MB/layer** (FP16), **161 MB/layer** (INT4)

4.2 가지치기 시나리오 (실측)

제거 레이어	유지	VLM FP16	VLM INT4	전체(VLM INT4+나머지 FP16)	12GB	품질
6	30	12.64 GB	3.16 GB	8.87 GB	OK	경미
9	27	11.38 GB	2.84 GB	8.55 GB	OK	중간
12	24	10.11 GB	2.53 GB	8.24 GB	OK	중간
18	18	7.58 GB	1.90 GB	7.61 GB	OK	심각
24	12	5.06 GB	1.26 GB	6.97 GB	OK	매우 심각

4.3 레이어 중요도 패턴

블록 중요도 측정 (cosine similarity 기반): - **제거 우선 후보**: 중간 레이어 (11-20번대) - 입출력 유사도가 높아 변환이 작음 - **유지 필수**: 초반 (0-3번) + 후반 (30-35번) 레이어 - 입/출력 특화

4.4 레이어 스킵 속도 벤치마크 (시뮬레이션)


레이어 수	시간	메모리	속도비
36 (전체)	7.06 ms	2,601 MB	1.00x
24	8.16 ms	1,737 MB	0.87x
18	9.16 ms	1,305 MB	0.77x
12	7.91 ms	873 MB	0.89x

참고: 시뮬레이션에서 속도비가 비선형인 이유는 축소된 모델(hidden=2048) 사용 + GPU 워밍업 영향.

4.5 평가

- **가능성**: 중간 - 실제 품질 영향 검증 필요 (minADE 등 메트릭)
- **구현 난이도**: 보통 - 레이어 인덱스 스킵은 간단, 품질 유지를 위한 distillation은 추가 작업
- **예상 효과**: 6개 레이어 제거 시 VLM ~17% 축소, 18개 제거 시 ~50% (but 심각한 품질 저하)

- INT4 + 6레이어 제거 조합: 전체 ~8.87 GB → ~8.56 GB (추가 ~300 MB 절감)



5. 동적 해상도 조절 (X — 배제: 모델 정확도 저하 방식)

5.1 Qwen3-VL Vision 토큰 분석

Alpamayo 기본 설정: 7 프레임, 각 320x576, min_pixels=163840, max_pixels=196608

해상도	조정 해상도	Vision 토큰	배율
320x576 (원본)	336x588	1,008	1.00x
224x400	308x560	880	0.87x
160x288	308x560	880	0.87x

핵심 발견: Qwen3-VL의 min_pixels/max_pixels 제약이 해상도 조정을 제한한다. 작은 이미지도 min_pixels(163840)까지 확대되어 토큰 수가 크게 줄지 않는다.

5.2 해상도 변경 시 메모리 영향

시나리오	KV Cache	Attention Act	Vision Act	총 동적 메모리
원본 320x576	310 MB	149 MB	8 MB	467 MB
축소 224x400	214 MB	71 MB	5 MB	290 MB
축소 160x288	117 MB	21 MB	3 MB	141 MB
축소 112x196	62 MB	6 MB	1 MB	69 MB

min_pixels 제약을 해제(또는 축소)하면 토큰 수를 크게 줄일 수 있다.

5.3 Attention 속도 벤치마크 (시퀀스 길이별)

Seq Len	시간 (us)	배율	스케일링 지수
256	325	1.00x	1.0
512	323	0.99x	-0.01
1,024	322	0.99x	-0.01
2,048	425	1.31x	0.13
4,096	698	2.15x	0.28

SDPA 덕분에 시퀀스 길이 ~2048까지는 거의 일정한 시간. 4096부터 서서히 증가.

5.4 트레이드오프 분석


설정	메모리 절감	속도 향상	품질 점수
원본 (baseline)	0%	0%	10/10
min_pixels=81920	25%	30%	8/10
min_pixels=40960	45%	55%	6/10
min_pixels=20480	55%	65%	3/10

5.5 Vision 처리 속도 실측

해상도	패치 수	처리 시간	GPU 메모리
320x576	902	1.375 ms	29.0 MB
224x400	448	0.850 ms	19.5 MB
160x288	220	0.603 ms	14.4 MB
112x196	112	0.353 ms	11.7 MB

5.6 평가

- **가능성: 높음** - min_pixels 파라미터 변경만으로 즉시 적용 가능
- **구현 난이도: 매우 쉬움** - `helper.py` 의 MIN_PIXELS 값 수정
- **예상 효과:** min_pixels 반으로 줄이면 동적 메모리 ~25% 절감, 속도 ~30% 향상
- **주의:** 자율주행에서 해상도 저하는 안전에 직결 → 품질 검증 필수



6. 디퓨전 스텝 축소 + Expert 경량화 (창의적 아이디어 1)

6.1 배경

Alpamayo의 Flow Matching은 **10 Euler 스텝**으로 궤적 생성. 각 스텝마다 Expert 모델 (hidden=2048, ~1.6 GB)이 forward pass를 수행한다.

6.2 스텝 수별 시간 실측 (시뮬레이션)

스텝	총 시간	스텝당 시간	Baseline 대비 Speedup	예상 품질
1	3.45 ms	3.45 ms	7.51x	매우 낮음 (2/10)
3	8.36 ms	2.79 ms	3.10x	낮음 (5/10)
5	13.98 ms	2.80 ms	1.85x	중간 (7/10)
8	20.78 ms	2.60 ms	1.25x	높음 (9/10)
10	25.90 ms	2.59 ms	1.00x	기본 (10/10)

6.3 Expert 모델 경량화 옵션

전략	FP16 크기	INT4/8 크기	품질 영향	속도 변화
Baseline Expert	1.6 GB	0.4 GB (INT4)	없음	-
Expert INT8	1.6 GB	0.8 GB	경미	유사
Expert 레이어 50% 축소	0.8 GB	0.2 GB	중간	2x 빠름
5스텝 + Expert INT8	1.6 GB	0.8 GB	중간	~2x 빠름

6.4 Consistency Distillation 가능성


- **원리:** 10-step ODE → 1-2 step 직접 예측 모델로 distillation
- **적용성:** 중간-높음 (Flow Matching에 직접 적용 가능)
- **예상 효과:** 디퓨전 단계 5-10x 가속 (전체 추론의 ~38% 차지하므로 전체 2-4x)
- **구현:** 학습 필요 → 어려움

6.5 파이프라인 시간 분석 (4-bit 기준)

단계	비율	시간 (추정)	최적화 가능성
Vision Encoding	~2%	~0.10s	해상도 축소
VLM Generation	~60%	~2.95s	Speculative / KV 최적화
Expert/Diffusion	~38%	~1.87s	스텝 축소 / Expert 경량화

6.6 평가

- **가능성: 높음** - 스텝 수 변경은 FlowMatching의 `num_inference_steps` 파라미터만 변경
- **구현 난이도: 쉬움** (스텝 축소) ~ **어려움** (Consistency Distillation)
- **예상 효과**: 5스텝으로 줄이면 디퓨전 단계 2x 가속 (전체 ~1.3x), Expert INT8 추가 시 ~300 MB 절감
- **위험**: 궤적 정확도 저하 (minADE 검증 필수)



7. Token Merging + Chunked Prefill (창의적 아이디어 2)

7.1 활성화 메모리 분석

추론 시 1 layer의 활성화 메모리 (이론, BF16):

Seq Len	QKV	Attn Score	FFN	총/layer	체크포인팅 후	절감률
256	6 MB	4 MB	14 MB	26 MB	2 MB	92%
1,024	24 MB	64 MB	56 MB	152 MB	8 MB	95%
4,414	104 MB	1,189 MB	214 MB	1,534 MB	34 MB	98%

Alpamayo의 ~4414 토큰에서 Attention Score가 1.2 GB로 지배적이지만, **SDPA (Scaled Dot-Product Attention)**가 이미 이를 최적화하여 $O(n^2)$ 메모리를 피함.

7.2 Chunked Prefill 벤치마크

Chunk 크기	Chunks	시간	Peak 메모리	시간 오버헤드	메모리 절감
128	16	10.52 ms	58 MB	4.93x	22%
256	8	2.92 ms	44 MB	1.37x	44%
512	4	1.57 ms	48 MB	0.73x	38%
2,048 (전체)	1	2.13 ms	72 MB	1.00x	0%

Chunk 크기 256이 최적 밸런스 (44% 메모리 절감, 37% 시간 오버헤드).

7.3 Token Merging (ToMe) 적용 가능성

- **원리:** 유사한 vision 토큰을 병합하여 시퀀스 길이 자체를 줄임
- **적용 대상:** Vision Encoder 출력 토큰 (~1008개) 중 인접/유사 패치 병합
- **예상 효과:** 30% 병합 시 vision 토큰 ~706개 → 전체 시퀀스 ~300토큰 감소 → KV cache ~43 MB 절감
- **구현:** Vision Encoder와 VLM 사이에 ToMe 모듈 삽입

7.4 Selective Recomputation 전략

전략	상태	적용 가능	효과
Attention Score 재계산 (Flash/SDPA)	이미 적용	-	$O(n^2)$ 메모리 회피
FFN 활성화 재계산	비해당 (추론)	X	학습에서만 유효
Chunked Prefill	미적용	O	활성화 메모리 ~44% 절감
Token Merging	미적용	O	시퀀스 축소로 메모리/속도 개선

7.5 평가

- **가능성: 중간-높음** - Chunked Prefill은 구현 가능, ToMe는 추가 실험 필요

- 구현 난이도: 보통 - vLLM/TGI 참조 가능 (Chunked Prefill), ToMe는 별도 구현
- 예상 효과: 활성화 메모리 ~44% 절감 (Chunked Prefill), 시퀀스 ~30% 축소 (ToMe)
- SDPA가 이미 적용되어 있어 추가 절감 효과는 제한적


8. 종합 평가 매트릭스

8.1 아이디어별 평가 요약

#	아이디어	가능성	효과	구현 난이도	VRAM 절감	속도 변화
1	하이브리드 양자화 (X — 배제)	높음	높음	보통	60-75%	+55x (INT4)
2	KV Cache 압축	중간-높음	중간	보통	~270 MB	중립
3	Speculative Decoding	낮음-중간	높음	어려움	중립~증가	1.5-3x
4	레이어 가지치기 (X — 배제)	중간	중간-높음	보통	17-50%	비례 향상
5	동적 해상도 조절 (X — 배제)	높음	중간	쉬움	25-55% (동적)	30-65%
6	디퓨전 스텝 축소	높음	중간	쉬움	미미	디퓨전 2x
7	Token Merging + Chunked Prefill	중간-높음	중간	보통	~44% (활성화)	가변

8.2 종합 우선순위 (가능성 x 효과 x 구현용이성)

순위	아이디어	종합 점수	권장 우선순위
1	하이브리드 양자화 (Attn-INT8 + FFN-INT4) (X — 배제)	3.00	즉시 실행
2	디퓨전 스텝 축소 (10→5)	2.40	즉시 실행
3	동적 해상도 조절 (min_pixels 축소) (X — 배제)	2.40	즉시 실행
4	KV Cache 압축	1.44	보조적 적용
5	Token Merging + Chunked Prefill	1.44	중기 연구
6	레이어 가지치기 (X — 배제)	0.96	장기 연구
7	Speculative Decoding	0.32	장기 연구



9. 최종 권장 연구 방향 Top 3

Top 1: 하이브리드 양자화 확장 (Attn-INT8 + FFN-INT4) (X — 배제: 모델 정확도 저하 방식)

이유: 기존 INT4 결과(8.87 GB, 4.91초)가 이미 성공적. Attention에 INT8을 적용하면 양자화 오차를 13x 줄이면서 메모리는 ~1 GB만 추가. FFN(80% 비중)은 INT4를 유지하여 전체 메모리 효율 극대화.

구현 계획: 1. bitsandbytes/GPTQ의 per-module precision 설정 2. Attention layers → INT8, MLP layers → INT4 적용 3. minADE 정확도 비교 (FP16 vs INT4 vs Hybrid) 4. Expert 모델에도 동일 적용 (INT8)

예상 결과: Peak VRAM ~6-7 GB, 정확도 INT4보다 개선

Top 2: 디퓨전 스텝 축소 (10 → 5)

이유: `num_inference_steps` 파라미터 변경만으로 즉시 적용. 전체 추론의 ~38% 차지하는 디퓨전 단계를 2x 가속. Flow Matching은 5 스텝에서도 수용 가능한 품질을 보이는 경우가 많다.

구현 계획: 1. FlowMatching의 `num_inference_steps` 를 5로 변경 2. minADE 비교 (10 vs 8 vs 5 vs 3 스텝) 3. 최적 스텝 수 결정 (품질-속도 곡선) 4. 장기적: Consistency Distillation으로 1-2 스텝 목표

예상 결과: 전체 추론 시간 ~20% 단축 (4.91초 → ~4.0초)

Top 3: 동적 해상도 + min_pixels 최적화 (X — 배제: 모델 정확도 저하 방식)

이유: `helper.py` 의 MIN_PIXELS=163840을 81920으로 줄이면 vision 토큰 ~13% 감소, KV cache ~25% 절감, 속도 ~30% 향상. 구현이 가장 간단하며 즉시 테스트 가능.

구현 계획: 1. MIN_PIXELS를 81920, 40960으로 변경하여 테스트 2. 시각적 품질 확인 (이미지가 얼마나 축소되는지) 3. minADE 영향 측정 4. Token Merging 추가 적용 검토

예상 결과: 동적 메모리 ~25% 절감, 전체 추론 ~15% 단축

10. 세 방향의 조합 최적화 시나리오

조합	Peak VRAM (추정)	추론 시간 (추정)	비고
기존 INT4	8.87 GB	4.91초	Baseline
Hybrid(Attn8+FFN4) + 5스텝	~7.5 GB	~4.0초	Top 1+2
Hybrid + 5스텝 + 저해상도	~6.5 GB	~3.2초	Top 1+2+3
전체 INT4 + 5스텝 + 저해상도 + KV INT8	~6.0 GB	~2.8초	최대 최적화

핵심 메시지: 단일 기법보다 조합이 효과적. Top 3 조합으로 기존 INT4 대비 추가 27% VRAM 절감 + 35% 속도 향상이 가능하며, 12 GB VRAM 내 안정적 동작을 보장한다.

부록: 실험 스크립트 및 결과 파일

번호	스크립트	결과 파일
1	<code>exp01_hybrid_quantization.py</code>	<code>exp01_hybrid_quant_results.json</code>
2	<code>exp02_kv_cache_analysis.py</code>	<code>exp02_kv_cache_results.json</code>
3	<code>exp03_speculative_decoding.py</code>	<code>exp03_speculative_results.json</code>
4	<code>exp04_layer_pruning.py</code>	<code>exp04_layer_pruning_results.json</code>
5	<code>exp05_dynamic_resolution.py</code>	<code>exp05_dynamic_resolution_results.json</code>
6	<code>exp06_diffusion_step_reduction.py</code>	<code>exp06_diffusion_step_results.json</code>
7	<code>exp07_activation_checkpointing.py</code>	<code>exp07_activation_checkpoint_results.json</code>

시각화

번호	파일명	내용
1	<code>figures/01_hybrid_quantization_memory.png</code>	양자화 시나리오별 VLM 메모리
2	<code>figures/02_kv_cache_analysis.png</code>	KV Cache 크기 및 압축 기법
3	<code>figures/03_layer_pruning.png</code>	레이어 가지치기 메모리 트레이드오프
4	<code>figures/04_dynamic_resolution.png</code>	해상도별 메모리/속도/품질
5	<code>figures/05_diffusion_steps.png</code>	디퓨전 스텝 축소 효과
6	<code>figures/06_priority_matrix.png</code>	종합 우선순위 매트릭스
7	<code>figures/07_offloading_strategies.png</code>	오프로딩 전략별 Peak VRAM