

Alpamayo VRAM 최적화 연구 탐색

날짜

2026-02-25

작성자

노승우

Alpamayo VRAM Optimization Research

목차 (Table of Contents)

연구 배경

연구 방향

선행연구

디렉토리 구조

Alpamayo VRAM 최적화 연구 탐색

시작일: 2026-02-25

연구 배경

- NVIDIA Alpamayo-R1-10B: 24GB VRAM 요구 자율주행 VLA 모델
- 목표: 12GB VRAM (RTX 3080 Ti)에서 효율적 구동
- FP16 베이스라인: 추론 273.79초, Peak VRAM 21.52GB (스왑 오버헤드)
- 4-bit 양자화: 추론 4.91초, Peak VRAM 8.87GB (스왑 없음)

연구 방향

#	방향	디렉토리	상태
1	On-Demand Layering (RTSS 2022 참고)	01-on-demand-layering/	탐색 중
2	메모리 관점 파이프라이닝	02-memory-pipelining/	탐색 중
3	CPU-GPU 스와핑 비효율 해결	03-swap-optimization/	탐색 중
4	창의적 접근 (새로운 주제)	04-creative-approaches/	탐색 중

선행연구

- Alpamayo 선행연구
- 관련 연구 (GPU 메모리 최적화)

디렉토리 구조

```
research/
├── README.md                # 이 파일
├── prior-work-alpamayo.md   # 알파마요 선행연구 정리
├── related-research.md     # 관련 연구 (Demand Layering 등)
├── final-report.md         # 통합 보고서 (최종)
├── 01-on-demand-layering/  # 연구 방향 1
│   ├── analysis.md
│   └── (실험 스크립트/데이터)
├── 02-memory-pipelining/   # 연구 방향 2
│   ├── analysis.md
│   └── (실험 스크립트/데이터)
├── 03-swap-optimization/   # 연구 방향 3
│   ├── analysis.md
│   └── (실험 스크립트/데이터)
├── 04-creative-approaches/ # 연구 방향 4
│   ├── analysis.md
│   └── (실험 스크립트/데이터)
```