

소비자 GPU 환경에서의 대규모 VLA 모델 On-Demand Layering 추론 최적화

날짜

2026-03-06

작성자

노승우

Alpamayo VRAM Optimization Research

목차 (Table of Contents)

연구 계획서

1. 연구 배경 및 동기

- 1.1 문제 정의
- 1.2 연구 대상 모델
- 1.3 하드웨어 환경
- 1.4 연구 제약 조건

2. 선행 연구 분석

- 2.1 기존 오프로딩 시스템 비교
- 2.2 기존 연구의 공백

3. 연구 목표

- 3.1 최종 목표
- 3.2 세부 목표

4. 예비 실험 결과 (Feasibility Study)

- 4.1 성과 요약
- 4.2 핵심 발견
- 4.3 이론적 한계 분석

5. 연구 방법론

- 5.1 전체 아키텍처
- 5.2 핵심 기법

6. 연구 계획

- 6.1 Phase 1: Pinned Memory 기반 최적 전송 (2주)
- 6.2 Phase 2: 2-Stream 비동기 파이프라인 안정화 (2주)
- 6.3 Phase 3: 디퓨전 스텝 최적화 (1주)
- 6.4 Phase 4: KV Cache 오프로딩 및 활성화 최적화 (2주)
- 6.5 Phase 5: 체계적 벤치마크 및 논문 작성 (3주)

7. 기대 성과

- 7.1 정량적 목표
- 7.2 학술적 기여
- 7.3 실용적 가치

8. 리스크 및 대응 방안

9. 일정 요약

참고 문헌

소비자 GPU 환경에서의 대규모 VLA 모델 On-Demand Layering 추론 최적화

연구 계획서

1. 연구 배경 및 동기

1.1 문제 정의

자율주행용 Vision-Language-Action (VLA) 모델의 규모가 급격히 증가하면서, 소비자급 GPU에서의 추론이 사실상 불가능해지는 VRAM 벽(VRAM Wall) 문제가 대두됨. 대표적으로 NVIDIA Alpamayo-R1-10B은 FP16 기준 **22.16 GB**의 파라미터 메모리를 요구하나, RTX 3080 Ti와 같은 소비자 GPU는 **12 GB VRAM**만 제공.

현재 유일한 대안인 CUDA Unified Memory의 페이지 폴트 기반 자동 스와핑은 **273.79초**의 추론 시간을 발생시키며, 이는 이론적 최적(~5.0초) 대비 **55배 느린** 수치. 추론 시간의 **98%가 순수 스와핑 오버헤드**에 해당.

1.2 연구 대상 모델

항목	사양
모델	NVIDIA Alpamayo-R1-10B
파라미터	11.08B (FP16 22.16 GB)
아키텍처	Vision Encoder (SigLIP, 1.15 GB) + VLM (Qwen3-VL-8B, 15.17 GB) + Expert (Flow Matching Decoder, 4.56 GB)
특징	Chain-of-Causation (CoC) 추론, 이기종 3-모듈 구조

1.3 하드웨어 환경

항목	사양
GPU	NVIDIA RTX 3080 Ti (12 GB VRAM, 912 GB/s)
CPU	Intel i7-10700K
RAM	15.55 GB
PCIe	Gen3 x16 (이론 15.75 GB/s, 실측 H2D 8.5 GB/s pinned)
OS	WSL2 (Linux 6.6.87.1)

1.4 연구 제약 조건

- **모델 정확도 보존:** 양자화, 가지치기, 지식 증류 등 모델 품질 저하 기법 배제
- **시스템/메모리 레벨 최적화에 집중:** 동일 FP16 가중치로 추론 속도 극대화
- **단일 소비자 GPU 환경 한정** (다중 GPU 기법 배제)

2. 선행 연구 분석

2.1 기존 오프로딩 시스템 비교

시스템	H2D Prefetch	D2H	대상	한계
DeepSpeed ZeRO-Inference	O	불필요	다중 GPU	단일 GPU 미지원
FlexGen (ICML 2023)	O	O	배치 처리	단일 요청 비효율
PIPO (2025)	O	O	LLM 서버	D2H 오버헤드 존재
HuggingFace Accelerate	최근 도입	GPU free	범용	모델별 커스텀 연산 비호환
vLLM	O	O	LLM 서버	다중 요청 최적화 특화

2.2 기존 연구의 공백

1. **D2H 불필요성 미인식**: 대부분의 오프로딩 시스템이 파라미터 추론에서 D2H copy를 수행하나, CPU 원본이 존재하는 경우 GPU 메모리 해제만으로 충분
2. **VLA 도메인 부재**: 기존 연구가 LLM/배치 서버에 집중, 이기종 모듈(Vision + Language + Action) 복합 구조에 대한 체계적 최적화 연구 부재
3. **소비자 GPU 실증 부족**: 대부분 A100/H100 급 환경 기준, 12 GB VRAM + PCIe Gen3 조건의 실질적 성능 분석 부족

3. 연구 목표

3.1 최종 목표

12 GB VRAM 소비자 GPU에서 FP16 Alpamayo-R1-10B의 추론 시간을 **CUDA Unified Memory 대비 10배 이상 개선** (273.79초 → **25초 이하**)하되, 모델 정확도 완전 보존.

3.2 세부 목표

목표	측정 지표	목표치
G1. 추론 시간 최소화	end-to-end 추론 시간	≤ 25초
G2. VRAM 한도 준수	Peak VRAM usage	≤ 11.5 GB
G3. 정확도 보존	출력 일치도 (vs 24 GB GPU)	100% (bitwise)
G4. 구조적 한계 규명	이론적 최적 대비 실측 비율	분석 및 문서화

4. 예비 실험 결과 (Feasibility Study)

본 연구는 8단계의 예비 실험을 통해 기술적 타당성을 확인 완료.

4.1 성과 요약

단계	방법	추론 시간	개선율
Baseline	FP16 + CUDA Unified Memory	273.79초	1.0x
Phase 1	On-Demand Layering (D2H 포함)	116.51초	2.35x
Phase 2	On-Demand Layering (D2H 제거)	43.38초	6.31x
Phase 3	비동기 Prefetch (2-stream)	38.45초	7.12x

4.2 핵심 발견

- D2H 불필요성 실증:** 파라미터 추론에서 `module.to("cpu")` 대신 GPU 메모리 free만 수행 시 116.51초 → 43.38초로 **2.68배 개선**. CPU에 원본 파라미터가 존재하므로 D2H copy는 완전히 불필요.
- WSL2 D2H 비정상 감속:** Pageable D2H 대역폭이 2.48 GB/s로, 정상(11.8 GB/s) 대비 **4.75배 느림**. Pinned memory 사용 시 정상 복구.
- 성능 절벽(Performance Cliff) 발견:** VRAM 10 GB → 9 GB 구간에서 추론 시간이 6.96초 → 111.36초로 **16배 급증**. 모델 크기와 VRAM 한계의 경계를 정밀하게 규명.
- 구조적 한계 규명:** PCIe Gen3 (8.5 GB/s) vs VRAM 대역폭 (912 GB/s)의 **107배 격차**로 인해, 레이어 전송 시간(~45 ms)이 레이어 실행 시간(~0.5 ms)의 **90배**. 파이프라이닝으로 전송을 연산에 완전 은닉하는 것은 구조적으로 불가능.


4.3 이론적 한계 분석

이론적 최적 추론 시간 (스왑 없음, ≥ 24 GB GPU):
VLM (256 토큰): $16.45 \text{ GB} / 912 \text{ GB/s} \times 256 = 4.62 \text{ 초}$
Expert (10 스텝): $4.56 \text{ GB} / 912 \text{ GB/s} \times 10 = 0.05 \text{ 초}$
합계: ~5.0초

12 GB VRAM + PCIe Gen3 환경 현실적 한계: ~25-40초
(이론 최적의 5-8배 수준)

5. 연구 방법론

5.1 전체 아키텍처



5.2 핵심 기법

기법 1: Zero-D2H On-Demand Layering

- CPU에 원본 파라미터 보존, GPU에서는 사용 후 메모리 free만 수행
- D2H copy 완전 제거로 전송 오버헤드 **60% 감소** (실증 완료)
- Forward hook 기반 자동화로 모델 코드 최소 수정

기법 2: 2-Stream Asynchronous Prefetch Pipeline

- Stream 0 (Compute): 현재 레이어 연산 실행

- Stream 1 (Transfer): 다음 레이어 H2D 프리페치
- 연산과 전송의 시간적 오버랩으로 유효 전송 시간 감소

기법 3: Pinned Memory + Optimal Chunking

- Pinned memory buffer pool로 안정적 H2D 대역폭 확보 (8.5 → 12.4 GB/s)
- 2-8 MB 최적 청크 크기로 per-transfer 오버헤드 최소화
- WSL2 환경의 0.36 ms 고정 오버헤드 완화

기법 4: 이기종 모듈 적응형 스케줄링

Alpamayo의 3-모듈 구조에 따른 차별화 전략:

모듈	크기	전략
Vision Encoder	1.15 GB	GPU 상주 (작은 크기, 1회 실행)
VLM (36 layers)	15.17 GB	On-demand layering (핵심 최적화 대상)
Expert (36 layers)	4.56 GB	GPU 상주 (10 스텝 반복 실행)

- VLM 36개 레이어 중 6개는 GPU 상주, 30개는 on-demand 로딩
- VRAM 예산: Vision(1.15) + VLM 상주(2.53) + Expert(4.56) + KV/Act(1.66) = **9.90 GB** → 여유 2.10 GB를 프리페치 버퍼로 활용

6. 연구 계획

6.1 Phase 1: Pinned Memory 기반 최적 전송 (2주)

목표: Pageable → Pinned memory 전환으로 H2D 대역폭 극대화

항목	내용
작업	Pinned buffer pool 구현, 최적 청크(2-8 MB) 적용
기대 효과	H2D 대역폭 7.77 → 12.4 GB/s (1.6배)
예상 추론 시간	43.38초 → ~30초
검증	추론 정확도 100% 일치 확인, VRAM ≤ 11.5 GB

6.2 Phase 2: 2-Stream 비동기 파이프라인 안정화 (2주)

목표: 프리페치 파이프라인의 정확성 보장 및 최적화

항목	내용
작업	Stream 동기화 정밀 제어, 프리페치 타이밍 최적화
기대 효과	연산-전송 오버랩으로 유효 전송 시간 15-20% 감소
예상 추론 시간	~30초 → ~25초
검증	CUDA event 기반 프로파일링, 출력 정확도 검증

6.3 Phase 3: 디퓨전 스텝 최적화 (1주)

목표: Expert 모듈의 디퓨전 스텝 축소 (10 → 5)

항목	내용
작업	<code>num_inference_steps</code> 조정, 궤적 품질 비교
기대 효과	Expert 단계 50% 감소, 전체 ~1.3배 추가 개선
예상 추론 시간	~25초 → ~20초
검증	생성 궤적의 정량적 비교 (L2 distance, 궤적 형태)

6.4 Phase 4: KV Cache 오프로딩 및 활성화 최적화 (2주)

목표: 동적 메모리 최적화로 VRAM 여유 확보 → 추가 레이어 GPU 상주

항목	내용
작업	KV Cache CPU 오프로딩, Chunked Prefill
기대 효과	~0.8 GB VRAM 절감 → 2개 추가 레이어 GPU 상주
예상 추론 시간	추가 ~5% 개선
검증	메모리 프로파일링, 추론 정확도 검증

6.5 Phase 5: 체계적 벤치마크 및 논문 작성 (3주)

목표: 최종 시스템의 체계적 성능 평가 및 논문 집필

항목	내용
작업	Ablation study, 다양한 VRAM 조건별 성능 측정, 관련 연구 비교
산출물	학회 논문 (시스템 최적화 분야)
비교 대상	CUDA Unified Memory, HF Accelerate, FlexGen

7. 기대 성과

7.1 정량적 목표

지표	Baseline	현재 최선	최종 목표
추론 시간	273.79초	38.45초	≤ 25 초
개선 배율	1.0x	7.12x	≥ 10 x
Peak VRAM	21.52 GB	11.03 GB	≤ 11.5 GB
정확도	100%	100%	100%

7.2 학술적 기여

- D2H 불필요성 실증:** 파라미터 추론에서 D2H copy가 불필요함을 정량적으로 입증하고, 이를 활용한 Zero-D2H 오프로딩 기법 제안
- VLA 도메인 최적화:** 이기종 모듈(Vision + Language + Action) 구조에 대한 적응형 메모리 스케줄링 기법 최초 제시
- 소비자 GPU 실용성:** 12 GB VRAM + PCIe Gen3 환경에서의 구조적 성능 한계 규명 및 실용적 최적화 달성
- 재현 가능한 벤치마크:** WSL2 + RTX 3080 Ti 환경의 체계적 성능 분석 데이터셋 공개

7.3 실용적 가치

- 소비자 GPU에서의 대규모 VLA 모델 추론 가능성 입증
- 에지 디바이스/로보틱스 분야에서의 온디바이스 추론 활용 경로 제시
- 오픈소스 구현체 공개를 통한 연구 커뮤니티 기여

8. 리스크 및 대응 방안

리스크	영향 도	대응 방안
25초 목표 미달성	중	Phase별 중간 결과가 이미 유의미 (38.45초 → 7.12x)
WSL2 특이 성능 이슈	중	네이티브 Linux 환경 전환으로 ~40% 추가 개선 가능
Pinned memory 시스템 RAM 부족	저	15.55 GB 중 ~4 GB를 버퍼로 할당, 충분한 여유
비동기 파이프라인 정확도 문제	고	CUDA stream 동기화 포인트 엄밀 관리, bitwise 검증

9. 일정 요약

Week 1-2: Phase 1 — Pinned Memory 최적 전송
Week 3-4: Phase 2 — 2-Stream 비동기 파이프라인
Week 5: Phase 3 — 디퓨전 스텝 최적화
Week 6-7: Phase 4 — KV Cache / 활성화 최적화
Week 8-10: Phase 5 — 벤치마크 및 논문 작성

참고 문헌

- Sheng et al., “FlexGen: High-Throughput Generative Inference of Large Language Models with a Single GPU,” ICML 2023
- Aminabadi et al., “DeepSpeed Inference: Enabling Efficient Inference of Transformer Models at Unprecedented Scale,” SC 2022
- NVIDIA, “Alpamayo: Scaling VLAs with Parameter-Efficient Expert Fusion,” 2025
- Kwon et al., “Efficient Memory Management for Large Language Model Serving with PagedAttention,” SOSP 2023
- Park et al., “PIPO: Efficient Pipelining for LLM Inference on Memory-Constrained GPUs,” 2025