

작업 로그 — 2026-03-09

날짜

2026-03-09

작성자

노승우

Alpamayo VRAM Optimization Research

목차 (Table of Contents)

5070ti 베이스라인 추론 실험

- 실험 개요
- OOM 확인 (.to("cuda") 방식)
- 베이스라인 결과 (device_map="auto")
- CoT 출력
- 비교 (WSL2 RTX 3080 Ti 12GB 기준)
- 산출물

5070ti 클럭고정 베이스라인 추론 실험

- 실험 개요
- 클럭 고정 확인
- 클럭고정 실험 결과
- 기본 vs 클럭고정 비교
- 분석
- 핵심 인사이트
- 산출물

5070ti Pinned Memory On-Demand Layering 실험

- 실험 개요
- 실험 방법
- 최종 결과
- 추론 시간 분해
- 비교 테이블 (5070 Ti)
- 핵심 분석
- 트러블슈팅 내역
- 산출물

작업 로그 — 2026-03-09

5070ti 베이스라인 추론 실험

실험 개요

- 목적: RTX 5070 Ti 16GB 환경에서 Alpamayo-R1-10B 베이스라인 추론 성능 측정
- 서버: 5070ti (avees@192.168.24.177, Ubuntu 24.04, Linux 6.17.0)
- 스크립트: `research/R1-5070ti/baseline/baseline_inference.py`

OOM 확인 (`.to("cuda")` 방식)

- 21.52GB 모델 > 16GB VRAM → `torch.OutOfMemoryError` 발생
- `.to("cuda")` 방식은 16GB에서도 실행 불가 확인

베이스라인 결과 (`device_map="auto"`)

항목	값
방식	<code>device_map="auto"</code>
GPU	RTX 5070 Ti 16GB
데이터 로드	60.10s
모델 로드	53.17s
추론 시간	184.99s
총 소요 시간	298.26s
Peak VRAM (allocated)	13.66 GB
Peak VRAM (reserved)	13.97 GB
minADE	2.5548m
CUDA 레이어	649개
CPU 오프로드 레이어	510개 (meta)

CoT 출력

```
[[ 'Nudge to the left to increase clearance from the construction cones encroaching into the lane.' ]]
```

비교 (WSL2 RTX 3080 Ti 12GB 기준)

환경	방식	추론 시간	비고
3080 Ti 12GB	FP16 베이스라인	273.79s	CUDA Unified Memory 스왑
3080 Ti 12GB	Demand Layering	43.38s	현재 최고 성과
5070 Ti 16GB	<code>device_map=auto</code>	184.99s	CPU 오프로드 510 레이어

산출물

- `research/R1-5070ti/baseline/baseline_inference.py`
- `research/R1-5070ti/baseline/baseline_results.json`

- `research/R1-5070ti/baseline/baseline_vram_timeline.json`
- `research/R1-5070ti/baseline/vram_timeline.png`
- `research/R1-5070ti/baseline/create_figures.py`

5070ti 클럭고정 베이스라인 추론 실험

실험 개요

- 목적: GPU 클럭/PCIe 최대 고정 후 추론 성능 변화 측정
- 클럭 고정 명령:
 - `nvidia-smi -pm 1` (Persistence mode)
 - `nvidia-smi -lgc 3090,3090` (Graphics clock lock)
 - `nvidia-smi -lmc 14001,14001` (Memory clock lock)
 - `nvidia-smi -pl 300` (Power limit 300W)
- 스크립트: `research/R1-5070ti/baseline/baseline_maxclock.py`

클럭 고정 확인

항목	기본 (아이들)	클럭 고정 후
Graphics Clock	180 MHz (P8)	2842 MHz (P0)
Memory Clock	405 MHz	14001 MHz
PCIe	Gen1 x16	Gen5 x16
Performance State	P8	P0
Power Limit	300W	300W

- Blackwell 아키텍처 (RTX 5070 Ti): `-lgc`, `-lmc` 명령 정상 동작 확인
- Graphics는 3090 MHz 요청이지만 실측 2842 MHz (부스트 범위 내 정상)

클럭고정 실험 결과

항목	값
방식	<code>device_map="auto"</code> (max clock)
GPU	RTX 5070 Ti 16GB
데이터 로드	60.86s
모델 로드	52.09s
추론 시간	168.95s
총 소요 시간	295.54s
Peak VRAM (allocated)	13.66 GB
Peak VRAM (reserved)	14.03 GB
minADE	2.5548m
CUDA 레이어	29개
CPU 레이어	17개

기본 vs 클럭고정 비교

항목	기본 (P8→P0)	클럭고정 (P0)	개선
추론 시간	184.99s	168.95s	-8.7% (1.09x)
모델 로드	53.17s	52.09s	-2.0%
Peak VRAM	13.66 GB	13.66 GB	동일
minADE	2.5548m	2.5548m	동일 (재현성 확인)

분석

- 클럭 고정으로 추론 시간 약 9% 개선 (184.99s → 168.95s)
- VRAM 사용량 동일 — 클럭이 병목이 아닌 CPU-GPU 통신(오프로드) 병목 확인
- `device_map="auto"` device placement: CUDA 29, CPU 17 (기본 실험의 649/510과 다름 — 실험 간 환경 차이)

- minADE 동일 → 재현성 확보

핵심 인사이트

- PCIe Gen5 x16 환경에서도 CPU 오프로드 레이어가 병목
- 클럭 자체보다 레이어 배치 최적화가 중요
- 5070 Ti (Gen5) vs 3080 Ti (Gen3) 비교: 5070 Ti가 오히려 느린 것은 CPU 오프로드 방식 차이

산출물

- `research/R1-5070ti/baseline/baseline_maxclock.py`
- `research/R1-5070ti/baseline/baseline_maxclock_results.json`
- `research/R1-5070ti/baseline/baseline_maxclock_vram_timeline.json`
- `research/R1-5070ti/baseline/vram_comparison.png`
- `research/R1-5070ti/baseline/inference_comparison.png`

5070ti Pinned Memory On-Demand Layering 실험

실험 개요

- 목적: CPU 오프로드 레이어를 `pin_memory()`로 고정하여 H2D DMA 전송 활용
- 비교 대상: 베이스라인 (`device_map=auto`, 184.99s)
- 스크립트: `research/R1-5070ti/pinned-memory/pinned_memory_inference.py`

실험 방법

1. 모델을 CPU FP16으로 로드 (38.39s)
2. Non-VLM 컴포넌트 + 상위 VLM 레이어 11개 → GPU
3. 하위 VLM 레이어 25개 → CPU
4. CPU 레이어를 `pin_memory()`로 변환 (DMA 전송용)
5. Forward hook: pinned CPU → GPU (H2D, `non_blocking=True`) → Free (D2H 없음)

최종 결과

항목	값
방식	Pinned Memory On-Demand Layering
GPU	RTX 5070 Ti 16GB
CPU 로드	38.39s
Setup (오프로드+핀닝)	64.09s
추론 시간	61.27s
베이스라인 대비	3.02x 향상
Peak VRAM	12.76 GB
H2D 평균	47.52 ms/layer
FREE 평균	11.46 ms/layer
Pin time	44.45s
minADE	2.5548m (정확도 유지)
H2D 총 횟수	550회

추론 시간 분해

단계	시간	비율
H2D 전송	26.14s	42.7%
FREE (GPU 해제)	6.31s	10.3%
연산	28.82s	47.0%

비교 테이블 (5070 Ti)

방식	추론 시간	속도향상	Peak VRAM
Baseline (device_map=auto)	184.99s	1.0x	13.66 GB
Max Clock Baseline	168.95s	1.09x	13.66 GB
Pinned Memory On-Demand	61.27s	3.02x	12.76 GB

핵심 분석

- PCIe Gen5 x16 환경에서 H2D 47.52ms/layer (WSL2 Gen3에서 측정 불가 비교)
- Pinned Memory: DMA 직접 전송으로 일반 pageable memory 대비 빠름
- H2D가 전체 추론의 42.7% 차지 → 추가 최적화 여지 있음
- D2H 없음 → FREE 단계는 포인터 교체 + cache clear만 (11.46ms)
- minADE 2.5548m → 베이스라인과 동일, 정확도 손실 없음

트러블슈팅 내역

1. Direct CUDA 생성 OOM: `torch.set_default_device("cuda")` 로 전체 모델 CUDA 생성 시 15.5GB 초과
2. `action_in_proj` CPU 잔류: `expert_decoder`를 GPU로 이동했지만 `action_in_proj` 누락 → 추가
3. `NUM_OFFLOAD` 조정: 17개로는 추론 중 VRAM 14.94GB → OOM, 25개로 12.76GB 안정

산출물

- `research/R1-5070ti/pinned-memory/pinned_memory_inference.py`
- `research/R1-5070ti/pinned-memory/results.json`
- `research/R1-5070ti/pinned-memory/vram_timeline.json`
- `research/R1-5070ti/pinned-memory/vram_timeline.png`
- `research/R1-5070ti/pinned-memory/comparison.png`
- `research/R1-5070ti/pinned-memory/h2d_analysis.png`