

Contents

Alpamayo VRAM 최적화 실험	1
디렉토리 구조	1
실험 결과 요약	1
Exp 1: FP16 베이스라인 (nvidia/Alpamayo-R1-10B)	1
Exp 2: 4-bit 양자화 (dwko/Alpamayo-R1-10B-4bit, BnB fp4)	1
실행 방법	2

Alpamayo VRAM 최적화 실험

Alpamayo-R1-10B 모델의 VRAM 사용량 분석 및 최적화를 위한 실험 스크립트와 데이터.

디렉토리 구조

```
experiments/
  figures/
    memory_timeline.png      # FP16 VRAM
    phase_breakdown.png      # FP16 Phase
    theory_vs_actual.png      # vs
    memory_timeline_4bit.png  # 4-bit VRAM
    phase_breakdown_4bit.png  # 4-bit Phase
    comparison_fp16_vs_4bit.png # FP16 vs 4-bit
  test_dummy_inference.py    #
  profile_memory.py           # FP16
  profile_memory_4bit.py      # 4-bit
  memory_profile.csv          # FP16
  memory_profile_4bit.csv     # 4-bit
  visualize_baseline.py       # FP16
  visualize_4bit.py           # 4-bit + FP16
  README.md
```

실험 결과 요약

Exp 1: FP16 베이스라인 (nvidia/Alpamayo-R1-10B)

- **Peak VRAM:** 21.52 GB (물리 12GB 초과 → Unified Memory 스왑)
- **VLM 추론:** 273.79초 (전체의 78.5%)
- **토큰 생성:** ~1.07초/토큰 (정상 대비 20~30배 느림)

Exp 2: 4-bit 양자화 (dwko/Alpamayo-R1-10B-4bit, BnB fp4)

- **Peak VRAM:** 8.87 GB (12GB 이내, 스왑 없음)
- **VLM 추론:** 4.51초 (FP16 대비 **55.8배 빠름**)
- **핵심 발견:** FP16의 273초 추론은 전부 메모리 스왑 오버헤드

실행 방법

```
# alpamayo venv  
source ../alpamayo/ar1_venv/bin/activate
```

```
# FP16  
python profile_memory.py
```

```
# 4-bit  
python profile_memory_4bit.py
```

```
#  
python visualize_baseline.py  
python visualize_4bit.py
```

sys.path 설정이 포함되어 있어 venv 활성화 없이도 실행 가능합니다.