

목차 (Table of Contents)

프로젝트 구조

환경

핵심 실험 결과

문서

Alpamemyo — Alpamayo VRAM 최적화 연구

NVIDIA Alpamayo-R1-10B (자율주행 VLA 모델, 24GB VRAM 요구)을 12GB VRAM 환경에서 효율적으로 구동하기 위한 연구 프로젝트.

프로젝트 구조

```
workspace/
├── alpamayo/                # NVlabs/alpamayo 원본 소스 (클론)
│   ├── src/                # alpamayo_r1 패키지
│   ├── ar1_venv/           # Python 3.12 가상환경
│   └── ...
├── experiments/            # 실험 스크립트, 데이터, 시각화
│   ├── figures/            # 시각화 결과 이미지
│   ├── profile_memory*.py  # 프로파일링 스크립트
│   ├── visualize*.py      # 시각화 스크립트
│   └── *.csv               # 프로파일링 데이터
├── docs/                   # 프로젝트 문서
│   ├── research.md         # 연구 방향성 (살아있는 문서)
│   ├── alpamayo-setup-guide.md # 설치/실행 가이드
│   └── work-log/           # 일별 작업 로그
└── 2026-02-25.md
```

환경

항목	스펙
GPU	RTX 3080 Ti 12GB
CPU	i7-10700K
RAM	16GB
PCIe	Gen 3 x16 (~16GB/s)
OS	WSL2 (Ubuntu)
CUDA	12.6

핵심 실험 결과

모델	Peak VRAM	추론 시간	비고
FP16 (원본)	21.52 GB	273.79초	Unified Memory 스왑 발생
4-bit (BnB fp4)	8.87 GB	4.51초	12GB 이내, 스왑 없음

핵심 발견: FP16의 273초 추론 시간은 연산이 아닌 **CPU↔GPU 메모리 스왑 오버헤드** (이론 0.6초 vs 실제 273초, ~456배 차이).

문서

- [연구 방향성](#) — 연구 목표, 실험 계획, 의사결정 로그
- [설치 가이드](#) — WSL2 환경 설치 및 실행 방법
- [실험 README](#) — 실험 스크립트 및 결과 상세