

Contents

Alpamemyo — Alpamayo VRAM 최적화 연구	1
프로젝트 구조	1
환경	1
핵심 실험 결과	1
문서	2

Alpamemyo — Alpamayo VRAM 최적화 연구

NVIDIA Alpamayo-R1-10B (자율주행 VLA 모델, 24GB VRAM 요구)을 12GB VRAM 환경에서 효율적으로 구동하기 위한 연구 프로젝트.

프로젝트 구조

```
workspace/
  alpamayo/          # NVlabs/alpamayo      ( )
    src/             # alpamayo_r1
    ar1_venv/        # Python 3.12
    ...
  experiments/       #      ,      ,
    figures/         #
    profile_memory*.py #
    visualize_*.py   #
    *.csv            #
  docs/              #
    research.md      #      ( )
    alpamayo-setup-guide.md # /
  work-log/          #
    2026-02-25.md
```

환경

항목	스펙
GPU	RTX 3080 Ti 12GB
CPU	i7-10700K
RAM	16GB
PCIe	Gen 3 x16 (~16GB/s)
OS	WSL2 (Ubuntu)
CUDA	12.6

핵심 실험 결과

모델	Peak VRAM	추론 시간	비고
FP16 (원본)	21.52 GB	273.79초	Unified Memory 스왑 발생
4-bit (BnB fp4)	8.87 GB	4.51초	12GB 이내, 스왑 없음

핵심 발견: FP16의 273초 추론 시간은 연산이 아닌 **CPU↔GPU 메모리 스왑 오버헤드** (이론 0.6초 vs 실제 273초, ~456배 차이).

문서

- 연구 방향성 — 연구 목표, 실험 계획, 의사결정 로그
- 설치 가이드 — WSL2 환경 설치 및 실행 방법
- 실험 README — 실험 스크립트 및 결과 상세