

목차 (Table of Contents)

1. 연구 개요
 - 1.1 배경
 - 1.2 연구 목표
 - 1.3 베이스라인 측정 결과
2. 실험 환경
 - 2.1 하드웨어
 - 2.2 소프트웨어
 - 2.3 모델 정보
3. 선행연구 요약
 - 3.1 Alpamayo 관련 연구
 - 3.2 GPU 메모리 최적화 관련 주요 연구
4. 연구 방향 1: On-Demand Layering
 - 4.1 핵심 발견
 - 4.2 실험 결과
 - 4.3 적용 가능성 판단
5. 연구 방향 2: 메모리 파이프라이닝
 - 5.1 핵심 발견
 - 5.2 실험 결과
 - 5.3 적용 가능성 판단
6. 연구 방향 3: CPU-GPU 스왑 최적화
 - 6.1 핵심 발견
 - 6.2 실험 결과
 - 6.3 적용 가능성 판단
7. 연구 방향 4: 창의적 접근
 - 7.1 7개 아이디어 분석 요약
 - 7.2 Top 3 권장
 - 7.3 종합 우선순위 매트릭스
8. 종합 분석 및 권장 전략
 - 8.1 4개 연구 방향 비교 종합
 - 8.2 최적 조합 전략 제안

8.3 구현 로드맵

9. 향후 연구 계획

Tier 1: 즉시 실행 가능한 작업

Tier 2: 중기 연구

Tier 3: 장기 연구

부록

A. 전체 실험 파일 목록

B. 생성된 시각화 목록

Alpamayo-R1-10B VRAM 최적화 연구 탐색 보고서

작성일: 2026-02-25 작성자: Claude (자율 연구 탐색)

1. 연구 개요

1.1 배경

NVIDIA Alpamayo-R1-10B는 자율주행을 위한 Vision-Language-Action(VLA) 모델로, 11.08B 파라미터(BF16 기준 22.16 GB)를 가진다. 이 모델의 FP16 추론에는 약 24GB VRAM이 요구되어, 12GB GPU(RTX 3080 Ti) 환경에서는 CUDA Unified Memory의 자동 스와핑에 의존하게 되며, 이로 인해 극심한 성능 저하가 발생한다.

1.2 연구 목표

- Alpamayo-R1-10B를 **12GB VRAM** 환경에서 효율적으로 구동하는 방법론 탐색
- CPU-GPU 메모리 스와핑의 구조적 비효율 원인 규명
- 4개 연구 방향에 대한 실험 기반 적용 가능성 판단
- 최적 조합 전략 도출

1.3 베이스라인 측정 결과

메트릭	FP16 (Baseline)	4-bit 양자화
추론 시간	273.79초	4.91초
Peak VRAM	21.52 GB	8.87 GB
12GB 이내 동작	불가 (Unified Memory)	가능
스와핑 발생	~9.5 GB 초과	없음

FP16 추론 273.79초의 실질적 원인이 메모리 스와핑 오버헤드임을 4-bit 실험으로 확인.

2. 실험 환경

2.1 하드웨어

항목	사양
GPU	NVIDIA GeForce RTX 3080 Ti (12 GB VRAM)
CPU	Intel i7-10700K
System RAM	15.55 GB (15 GB 실효)
Swap	4 GB
PCIe	Gen3 x16 (이론 최대 15.75 GB/s)

2.2 소프트웨어

항목	버전
OS	WSL2 (Kernel 6.6.87.1-microsoft-standard-WSL2)
Python	3.12.12
PyTorch	2.8.0+cu128
CUDA	12.8
Transformers	4.57.1
Accelerate	1.12.0

2.3 모델 정보

항목	내용
모델	nvidia/Alpamayo-R1-10B
총 파라미터	11.08B
FP16/BF16 크기	22.16 GB
아키텍처	Vision Encoder (SigLIP) + VLM (Qwen3-VL-8B) + Expert (Trajectory Decoder)
추론 흐름	Vision Encoding -> VLM CoT 생성 -> Flow Matching (10 Euler steps)

3. 선행연구 요약

3.1 Alpamayo 관련 연구

Alpamayo-R1은 NVIDIA가 개발한 세계 최초의 산업 규모 오픈 추론 VLA 모델이다 (NeurIPS 2025 공개, CES 2026 출시).

항목	내용
핵심 기여	Chain of Causation(CoC) 데이터셋 + 모듈형 VLA + RL 후학습
구성	Cosmos-Reason (8.2B VLM) + Diffusion 궤적 디코더 (2.3B)
성능	궤적 정확도 12% 향상, 근접 조우율 35% 감소, 지연 99ms
산업 적용	Mercedes-Benz CLA, JLR, Lucid Motors, Uber

관련 연구로 ReasonPlan, Drive-R1, AutoVLA 등이 유사한 추론 VLA 접근법을 제안하고 있으며, Cosmos-Reason1(VLM 백본), DeepSeek-R1(GRPO 기반 RL) 등이 기반 기술로 활용된다.

상세: [prior-work-alpamayo.md](#)

3.2 GPU 메모리 최적화 관련 주요 연구

RTSS 2022 Demand Layering 논문을 중심으로 25편의 관련 연구를 조사했다.

분류	핵심 연구	Alpamayo 관련성
Demand Layering	Ji et al. (RTSS 2022)	높음 - 레이어별 순차 로딩으로 96.5% 메모리 절감
모델 오프로딩	FlexGen (ICML 2023), NEO (MLSys 2025)	높음 - LP 기반 최적 오프로딩, KV Cache 오프로딩
파이프라이닝	PIPO (2025), Superpipeline (2024)	매우 높음 - 소비자 GPU에서 검증된 파이프라인
양자화 (X — 배제: 모델 정확도 저하 방식)	AWQ (MLSys 2024), Q-VLM (NeurIPS 2024)	매우 높음 - VLM 특화 후학습 양자화
KV Cache	PagedAttention (SOSP 2023)	높음 - KV Cache 메모리 효율 극대화
VLM 서빙	Nova (2025)	매우 높음 - VLM 다단계 파이프라인 최적화
Diffusers	HuggingFace group_offload + CUDA Stream	매우 높음 - Demand Layering과 유사한 네이티브 기법

상세: [related-research.md](#)

4. 연구 방향 1: On-Demand Layering

4.1 핵심 발견

Alpamayo의 레이어 구조를 정밀 분석한 결과, VLM Language Model이 전체 메모리의 **68.5%**(15.17 GB)를 차지하여 12GB VRAM의 최대 병목임을 확인했다.

컴포넌트	파라미터	메모리 (BF16)	비율
Vision Encoder	576.4M	1.15 GB	5.2%
VLM Language Model	7.58B	15.17 GB	68.5%
VLM LM Head	637.7M	1.28 GB	5.8%
Expert (Trajectory Decoder)	2.28B	4.56 GB	20.6%

4.2 실험 결과

device_map="auto" 실험: 모델 로드는 성공(8.99 GB VRAM)했으나, **추론 실패**.

`fuse_traj_tokens()` 의 `masked_scatter` 연산에서 디바이스 분산 배치와 비호환 발생.

수동 오프로딩 실험: 동일한 디바이스 불일치 오류로 추론 실패. VLM 단독(16.44 GB)이 12 GB를 초과하여 모듈 단위 순차 로딩도 불가.

4.3 적용 가능성 판단

시나리오	피크 VRAM	실현성
순수 레이어별 로딩 (BF16)	~1.8 GB	높음 (구현 매우 복잡)
INT4 양자화 + 순차 오프로딩 (X — 배제: 양자화 - 모델 정확도 저하)	~6.1 GB	매우 높음 (권장)
모듈별 순차 로딩 (BF16)	~18.4 GB	불가능

결론: `device_map` 및 accelerate 기반 자동 오프로딩은 Alpamayo의 커스텀 토큰 처리와 비호환. INT4 양자화 (X — 배제) + 커스텀 레이어별 오프로딩이 실현 가능한 경로.

상세: [01-on-demand-layering/analysis.md](#) 시각화: [01-on-demand-layering/figures/](#)

5. 연구 방향 2: 메모리 파이프라이닝

5.1 핵심 발견

발견	수치
PCIe H2D 대역폭 (pageable)	7.77 GB/s
PCIe D2H 대역폭 (pageable)	2.48 GB/s (H2D의 1/3)
VLM 단일 레이어 크기	0.386 GB
레이어당 H2D 전송 시간	0.344s
CUDA 스트림 비동기 프리페치 속도업	1.53x
VLM 레이어별 비동기 파이프라인 속도업 (추정)	4.58x

5.2 실험 결과

- **Vision Encoder** (1.15 GB): GPU 단독 탑재 가능, CPU->GPU 0.374s
- **Expert** (4.56 GB): GPU 단독 탑재 가능, CPU->GPU 0.890s, forward 0.338s
- **VLM 전체** (17.60 GB): 단독 탑재 불가, 레이어별 탑재 필수

이론적 순차 오프로딩 피크 VRAM: **~6.5 GB** (Expert + KV Cache가 병목)

5.3 적용 가능성 판단

전략	피크 VRAM	추정 추론 시간	실현성
레이어별 동기식 (BF16)	~6.5 GB	~500-800s+	이론적 가능
레이어별 비동기 (BF16)	~6.5 GB	~400-600s+	이론적 가능
INT4 + 모듈 순차 오프로딩 (X — 배제: 양자화)	~5.5-6 GB	~300-400s	가장 현실적
INT4 + 전체 GPU 탑재 (X — 배제: 양자화)	~5.5 GB	~300-350s	최적

결론: 모듈 순차 오프로딩은 이론적으로 가능하나, Autoregressive 디코딩에서 매 토큰마다 36 개 레이어 순회로 전송 오버헤드가 극대화됨. INT4 양자화 (X — 배제)와의 조합이 필수.

상세: [02-memory-pipelining/analysis.md](#) 시각화: [02-memory-pipelining/figures/](#)

6. 연구 방향 3: CPU-GPU 스왑 최적화

6.1 핵심 발견

발견	수치
WSL2 Pageable D2H 감속	4.5x (pinned 대비)
Pinned H2D 대역폭	8.5 GB/s
Pinned D2H 대역폭	11.8 GB/s (H2D보다 빠름!)
최적 전송 청크 크기	2-8 MB (12.4 GB/s, 단일 전송의 1.6x)
12GB 초과 시 접근 시간 급증	26x
WSL2 per-transfer 고정 오버헤드	0.36 ms
cudaMemPrefetchAsync(CPU)	WSL2 미지원

6.2 실험 결과

방향 2 결과 수정: Pageable D2H 2.48 GB/s는 WSL2의 비정상적 감속이 원인. Pinned memory 사용 시 D2H가 H2D보다 1.4배 빠름 (11.8 vs 8.5 GB/s).

273.79초 추론의 근본 원인: 1. 페이지 폴트 기반 4KB~2MB 단위 on-demand 전송 (대역폭 효율 저하) 2. WSL2 Pageable D2H 비정상 (pinned 대비 4.5x 느림) 3. 12GB 초과 접근 시간 26x 급증 4. 양방향 전송 경합 (D2H 2.05x 감속) 5. Transformer attention의 비순차적 접근 패턴

6.3 적용 가능성 판단

전략	추정 추론 시간	VRAM	실현성
Baseline (Unified Memory)	273.79s	21.52 GB	현재
Pinned Memory 스와핑	~150-200s	~6.5 GB	가능
최적 Granularity (2-8MB)	~130-180s	~6.5 GB	가능
INT4 + Pinned (X — 배제: 양자화)	~80-120s	~5.5 GB	가장 현실적

결론: Pinned memory 사용이 필수 (특히 D2H). 2-8MB 청크 전송으로 대역폭 1.6x 향상 가능. 가능하면 네이티브 Linux 환경이 WSL2 대비 40% 오버헤드 제거.

상세: [03-swap-optimization/analysis.md](#) 시각화: [03-swap-optimization/figures/](#)

7. 연구 방향 4: 창의적 접근

7.1 7개 아이디어 분석 요약

#	아이디어	가능성	효과	구현 난이도	VRAM 절감
1	하이브리드 양자화 (Attn-INT8 + FFN-INT4) (X — 배제: 모델 정확도 저하 방식)	높음	높음	보통	60-75%
2	KV Cache 압축/오프로딩	중간-높음	중간	보통	~270 MB
3	Speculative Decoding	낮음-중간	높음	어려움	중립
4	레이어 가지치기 (X — 배제: 모델 정확도 저하 방식)	중간	중간-높음	보통	17-50%
5	동적 해상도 조절 (X — 배제: 모델 정확도 저하 방식)	높음	중간	쉬움	25-55% (동적)
6	디퓨전 스텝 축소 (10->5)	높음	중간	쉬움	미미
7	Token Merging + Chunked Prefill	중간-높음	중간	보통	~44% (활성화)

7.2 Top 3 권장

순위	아이디어	종합 점수	권장
1	하이브리드 양자화 (Attn-INT8 + FFN-INT4) (X — 배제)	3.00	즉시 실행
2	디퓨전 스텝 축소 (10->5 steps)	2.40	즉시 실행
3	동적 해상도 조절 (min_pixels 축소) (X — 배제)	2.40	즉시 실행

하이브리드 양자화: FFN이 레이어의 80%를 차지하므로 INT4 적용 시 메모리 효율 극대화, Attention은 INT8로 정확도 유지. 실측: VLM 6.03 GB (FP16의 70% 절감).

디퓨전 스텝 축소: `num_inference_steps` 파라미터 변경만으로 적용. Flow Matching 5 스텝 시 디퓨전 단계 2x 가속 (전체 ~1.3x).

동적 해상도: `MIN_PIXELS` 값 수정만으로 적용. 반으로 줄이면 동적 메모리 ~25% 절감, 속도 ~30% 향상.

7.3 종합 우선순위 매트릭스

순위	아이디어	종합 점수	우선순위
1	하이브리드 양자화 (X — 배제)	3.00	즉시 실행
2	디퓨전 스텝 축소	2.40	즉시 실행
3	동적 해상도 조절 (X — 배제)	2.40	즉시 실행
4	KV Cache 압축	1.44	보조적 적용
5	Token Merging + Chunked Prefill	1.44	중기 연구
6	레이어 가지치기 (X — 배제)	0.96	장기 연구
7	Speculative Decoding	0.32	장기 연구

상세: [04-creative-approaches/analysis.md](#) 시각화: [04-creative-approaches/figures/](#)

8. 종합 분석 및 권장 전략

8.1 4개 연구 방향 비교 종합

방향	핵심 결론	피크 VRAM	추론 시간	구현 난이도	실현성
1. On-Demand Layering	device_map 비호환, 커스텀 구현 필요	~1.8-6.1 GB	~300-400s	매우 높음	제한적
2. 메모리 파이 프라이닝	비동기 프리페치 1.53x, 레이어별 가능	~6.5 GB	~400-600s	매우 높음	이론적
3. 스왑 최적화	Pinned 필수, 2-8MB 최적, D2H 4.5x 개선	~5.5-6.5 GB	~80-200s	높음	가능
4. 창의적 접근	하이브리드 양자화 (X — 배제) + 스텝/해상도 최적화 (해상도: X — 배제)	~6.0-7.5 GB	~3.2-4.0s	보통	매우 높음

8.2 최적 조합 전략 제안

권장 조합: INT4 양자화 (X — 배제: 모델 정확도 저하) + 디퓨전 스텝 축소 + 동적 해상도 조절 (X — 배제: 모델 정확도 저하)

조합	Peak VRAM (추정)	추론 시간 (추정)
기존 INT4 (baseline)	8.87 GB	4.91초
Hybrid(Attn8+FFN4) + 5스텝	~7.5 GB	~4.0초
Hybrid + 5스텝 + 저해상도	~6.5 GB	~3.2초
최대 최적화 (전체 INT4 + 5스텝 + 저해상도 + KV INT8)	~6.0 GB	~2.8초

핵심 메시지: Top 3 조합 시 기존 INT4 대비 추가 27% VRAM 절감 + 35% 속도 향상, 12GB VRAM 내 안정적 동작 보장.

8.3 구현 로드맵

Phase 1: 즉시 실행 (1-2일) 1. 하이브리드 양자화 적용 (Attn-INT8 + FFN-INT4) (**X — 배제: 모델 정확도 저하 방식**) 2. 디퓨전 스텝 10->5 변경 및 minADE 비교 3. min_pixels 축소 (163840->81920) 테스트 (**X — 배제: 모델 정확도 저하 방식**)

Phase 2: 단기 최적화 (1주) 4. KV Cache INT8 양자화 적용 (**X — 배제: 양자화 기반 정확도 저하 방식**) 5. Pinned memory 기반 명시적 스와핑 프로토타입 6. 2-8MB 청크 전송 최적화

Phase 3: 중기 연구 (2-4주) 7. 커스텀 레이어별 오프로딩 구현 (generate() 수정) 8. Token Merging 적용 검토 9. Chunked Prefill 구현

9. 향후 연구 계획

Tier 1: 즉시 실행 가능한 작업

작업	예상 소요	예상 효과
하이브리드 양자화 (Attn-INT8 + FFN-INT4) (X — 배제)	0.5일	VRAM ~7 GB, 정확도 개선
디퓨전 스텝 축소 (10->5) + 품질 검증	0.5일	디퓨전 단계 2x 가속
min_pixels 최적화 + 품질 검증 (X — 배제)	0.5일	동적 메모리 25% 절감
KV Cache INT8 양자화 (X — 배제)	0.5일	~270 MB 추가 절감

Tier 2: 중기 연구

작업	예상 소요	예상 효과
Pinned memory 기반 명시적 스와핑	1주	스와핑 시 D2H 4.5x 개선
커스텀 레이어별 오프로딩 (generate 수정)	2주	피크 VRAM ~2-3 GB
Token Merging 적용	1주	시퀀스 30% 축소
Chunked Prefill	1주	활성화 메모리 44% 절감

Tier 3: 장기 연구

작업	예상 소요	예상 효과
Expert Consistency Distillation (10->1-2 steps)	2-4주	디퓨전 5-10x 가속
레이어 가지치기 + 지식 증류 (X — 배제)	4주	VLM 17-50% 축소
Speculative Decoding (Layer-skipping)	2-3주	VLM 단계 2-6x 가속
네이티브 Linux 환경 전환	1일	WSL2 오버헤드 40% 제거

부록

A. 전체 실험 파일 목록

연구 방향	디렉토리	주요 파일
선행연구 (Alpamayo)	<code>research/</code>	<code>prior-work-alpamayo.md</code>
관련 연구 (GPU 메모리)	<code>research/</code>	<code>related-research.md</code>
방향 1: On-Demand Layering	<code>research/01-on-demand-layering/</code>	<code>analysis.md</code> , <code>analyze_layers.py</code> , <code>test_device_map.py</code> , <code>test_manual_offload.py</code> , <code>create_figures.py</code>
방향 2: 메모리 파이프라이닝	<code>research/02-memory-pipelining/</code>	<code>analysis.md</code> , <code>test_sequential_offload.py</code> , <code>test_async_transfer.py</code> , <code>create_figures.py</code>
방향 3: 스왑 최적화	<code>research/03-swap-optimization/</code>	<code>analysis.md</code> , <code>analyze_unified_memory.py</code> , <code>test_prefetch.py</code> , <code>test_pinned_transfer.py</code> , <code>analyze_wsl2_overhead.py</code> , <code>create_figures.py</code>
방향 4: 창의적 접근	<code>research/04-creative-approaches/</code>	<code>analysis.md</code> , <code>exp01_hybrid_quantization.py</code> ~ <code>exp07_activation_checkpointing.py</code> , <code>create_figures.py</code>
통합 보고서	<code>research/</code>	<code>final-report.md</code>

B. 생성된 시각화 목록

방 향	시각화 파일	설명
1	01-on-demand-layering/figures/ 01_memory_distribution.png	서브모듈별 메모리 분포
1	01-on-demand-layering/figures/ 02_device_map_analysis.png	device_map 배치 분석
1	01-on-demand-layering/figures/ 03_strategy_comparison.png	전략 비교
1	01-on-demand-layering/figures/04_per_stage_vram.png	모듈별 VRAM (BF16 vs INT4)
1	01-on-demand-layering/figures/05_pipeline_diagram.png	On-Demand Layering 파이프라인
2	02-memory-pipelining/figures/01_pipeline_diagram.png	추론 파이프라인 구조
2	02-memory-pipelining/figures/02_vram_timeline.png	VRAM 시계열
2	02-memory-pipelining/figures/ 03_strategy_comparison.png	전략 비교
2	02-memory-pipelining/figures/04_pcie_bandwidth.png	PCIe 대역폭 측정
2	02-memory-pipelining/figures/05_layerwise_analysis.png	모듈별 상세 분석
3	03-swap-optimization/figures/ 01_unified_memory_timeline.png	Unified Memory 모니터링
3	03-swap-optimization/figures/ 02_bandwidth_comparison.png	Pinned vs Pageable 대역폭
3	03-swap-optimization/figures/ 03_granularity_bandwidth.png	전송 단위 vs 대역폭
3	03-swap-optimization/figures/04_wsl2_overhead.png	WSL2 오버헤드 분석
3	03-swap-optimization/figures/ 05_strategy_comparison.png	스왑 전략 비교
3	03-swap-optimization/figures/06_transfer_scaling.png	전송 크기별 스케일링
4		하이브리드 양자화 메모리

방 향	시각화 파일	설명
	04-creative-approaches/figures/ 01_hybrid_quantization_memory.png	
4	04-creative-approaches/figures/ 02_kv_cache_analysis.png	KV Cache 분석
4	04-creative-approaches/figures/03_layer_pruning.png	레이어 가지치기
4	04-creative-approaches/figures/ 04_dynamic_resolution.png	동적 해상도
4	04-creative-approaches/figures/05_diffusion_steps.png	디퓨전 스텝 축소
4	04-creative-approaches/figures/06_priority_matrix.png	종합 우선순위 매트릭스
4	04-creative-approaches/figures/ 07_offloading_strategies.png	오프로딩 전략별 Peak VRAM