

Contents

Alpamayo VRAM 최적화 연구 탐색	1
연구 배경	1
연구 방향	1
선행연구	1
디렉토리 구조	1

Alpamayo VRAM 최적화 연구 탐색

시작일: 2026-02-25

연구 배경

- NVIDIA Alpamayo-R1-10B: 24GB VRAM 요구 자율주행 VLA 모델
- 목표: 12GB VRAM (RTX 3080 Ti)에서 효율적 구동
- FP16 베이스라인: 추론 273.79초, Peak VRAM 21.52GB (스왑 오버헤드)
- 4-bit 양자화: 추론 4.91초, Peak VRAM 8.87GB (스왑 없음)

연구 방향

#	방향	디렉토리	상태
1	On-Demand Layering (RTSS 2022 참고)	01-on-demand-layering/	탐색 중
2	메모리 관점 파이프라이닝	02-memory-pipelining/	탐색 중
3	CPU-GPU 스와핑 비효율 해결	03-swap-optimization/	탐색 중
4	창의적 접근 (새로운 주제)	04-creative-approaches/	탐색 중

선행연구

- Alpamayo 선행연구
- 관련 연구 (GPU 메모리 최적화)

디렉토리 구조

```
research/
  README.md          #
  prior-work-alpamayo.md  #
  related-research.md  #   (Demand Layering )
  final-report.md      #   ( )
  01-on-demand-layering/  #   1
    analysis.md
    ( / )
  02-memory-pipelining/  #   2
    analysis.md
    ( / )
```

03-swap-optimization/ analysis.md (/)	#	3
04-creative-approaches/ analysis.md (/)	#	4