

목차 (Table of Contents)

교수님 아이디어: 2-Stage 모듈 스와핑

아이디어 내용

실제 적용 시 효과 (Alpamayo 기준)

이미 존재하는 메커니즘: `device_map="auto"`

교수님 아이디어와 `device_map="auto"`의 차이

단, Alpamayo에서는 `device_map="auto"`가 동작하지 않음

그래서 우리 연구가 필요한 이유

스왑 최적화의 근본적 한계 분석

FP16 이론적 최적 추론 시간 (스왑 없는 경우)

VRAM 대역폭 vs PCIe 대역폭 격차

파이프라이닝이 효과 없는 이유

결론: 성능 한계선

WSL2 환경에 의한 추가 오버헤드

측정된 WSL2 오버헤드

WSL2가 미치는 영향

의미

VRAM 점유 비율 분석

추론 시 VRAM 구성

핵심 관찰

시각화

교수님 면담 자료 #1

작성일: 2026-02-25

교수님 아이디어: 2-Stage 모듈 스와핑

아이디어 내용

- 비전-프리필 과정과 디코딩 과정을 2-stage로 나눠서 VRAM에 로딩/언로딩
- 사용하는 모듈만 VRAM에 올리고, 끝나면 내림
- 이렇게 하면 VRAM 사용량을 절반으로 줄일 수 있지 않을까?

실제 적용 시 효과 (Alpamayo 기준)

단계	모듈	크기 (BF16)
1	Vision Encoder	1.15 GB
2	VLM (LLM)	15.17 GB
3	Diffusion Decoder	4.56 GB
전체 동시 로드		~21 GB
모듈 스와핑 시 Peak	max(1.15, 15.17, 4.56)	~15.17 GB

→ 21GB → 15.17GB로 감소. **약 28% 절감** (절반까지는 아님)

이미 존재하는 메커니즘: `device_map="auto"`

이 아이디어는 HuggingFace Accelerate 라이브러리의 `device_map="auto"` 기능으로 이미 자동화되어 있음.

```
model = AutoModelForCausalLM.from_pretrained("model_name", device_map="auto")
```

device_map="auto"의 동작: 1. 모델 로드 시 VRAM 용량을 확인 2. VRAM에 들어가는 레이어는 GPU에 배치 3. 초과분은 CPU RAM에 배치 (그래도 부족하면 디스크) 4. 추론 시 CPU에 있는 레이어를 실행 차례에 GPU로 이동 → 완료 후 CPU로 반환

교수님 아이디어와 device_map="auto"의 차이

	교수님 아이디어	device_map="auto"
스와핑 단위	모듈 단위 (Vision / VLM / Diffusion)	레이어 단위 (개별 Transformer 레이어)
구현	수동 (명시적 <code>.to(cuda)</code> / <code>.to(cpu)</code>)	자동 (Accelerate 라이브러리)
개념	동일 — “쓸 때만 올리고 내린다”	동일 — “쓸 때만 올리고 내린다”

→ **핵심은 같음:** 필요할 때만 VRAM에 올리고, 끝나면 내리는 방식. device_map이 이를 레이어 단위로 더 세밀하게 자동 수행.

단, Alpamayo에서는 device_map="auto"가 동작하지 않음

실패 원인: Alpamayo의 `fuse_traj_tokens()` 커스텀 연산 - VLM 출력 텐서와 trajectory 토큰 테이블을 `masked_scatter` 로 합치는 과정 - device_map이 텐서를 GPU/CPU에 분산 배치하면 **디바이스 불일치 에러** 발생 - 실제 테스트에서 CUDA assertion error 확인 (연구 방향 1 실험)

그래서 우리 연구가 필요한 이유

1. 기존 device_map="auto"는 Alpamayo 비호환 → **커스텀 오프로딩 구현 필요**
2. 모듈 단위 스와핑만으로는 VLM(15.17GB) > 12GB VRAM → **레이어 단위 스와핑도 필요**
3. 단순 스와핑은 느림 (Unified Memory 기반 273초) → **명시적 전송 + 파이프라이닝 최적화 필요**

→ 모듈 스와핑(교수님 아이디어) + 레이어 스와핑 + pinned memory + 비동기 프리페치를 **조합한 커스텀 구현**이 연구의 핵심

스왑 최적화의 근본적 한계 분석

FP16 이론적 최적 추론 시간 (스왑 없는 경우)

GPU 메모리 대역폭(912 GB/s)으로부터 산출:

단계	읽기량	반복	시간
VLM (토큰 생성)	16.45 GB/토큰	256회	4.62s
Expert (디퓨전)	4.56 GB/스텝	10회	0.05s
Vision + KV Cache 등			~0.3s
합계			≈ 5.0s

연산 시간(0.44ms/토큰)은 읽기 시간(18ms/토큰)의 2.4%로 무시 가능. (Memory-bandwidth-bound)

VRAM 대역폭 vs PCIe 대역폭 격차

경로	대역폭	토큰당 9.5GB 스왑	256토큰
VRAM 내부	912 GB/s	10ms	2.6s
PCIe Gen3 (pinned)	8.5 GB/s	1,118ms	286s
격차	107배		

파이프라이닝이 효과 없는 이유

실제 상황 (전송 >> 실행):

전송: [=====] 45ms/레이어
 실행: [=====] [=] 0.5ms/레이어
 → 44.5ms 대기 불가피

레이어 실행(0.5ms)이 전송(45ms)보다 90배 빠름 → 전송을 연산으로 은닉 불가능

결론: 성능 한계선

전략	추론 시간	이론 최적 대비
이론 최적 (스왑 없음, ≥24GB GPU)	~5s	1x
최선의 스왑 최적화 (12GB)	~80-150s	16-30x
현재 Baseline (Unified Memory)	273.79s	55x

스왑 최적화로 273초 → 80~150초 개선은 가능하나, 5초에는 도달 불가능.

이 격차를 해소하려면: 1. VRAM 증설 (24GB+ GPU) 2. 모델 축소 (양자화 — 연구에서 배제)
3. 더 빠른 인터커넥트 (PCIe Gen5: 2배, NVLink: 10배+)

→ 12GB VRAM + PCIe Gen3 환경에서 스왑 없는 성능에 근접하는 것은 **구조적으로 불가능**.
이것이 연구의 현실적 한계선.

WSL2 환경에 의한 추가 오버헤드

현재 실험 환경은 **네이티브 Linux가 아닌 WSL2** 위에서 동작한다. WSL2는 GPU 접근 시 추가적인 오버헤드를 발생시킨다.

측정된 WSL2 오버헤드

항목	WSL2 (현재)	네이티브 Linux (예상)	차이
Pageable D2H 대역폭	2.48 GB/s	~11 GB/s	4.5배 느림
Pinned D2H 대역폭	11.8 GB/s	~12+ GB/s	유사
Pageable H2D 대역폭	7.77 GB/s	~8+ GB/s	유사
per-transfer 고정 오버헤드	0.36 ms	~0.05 ms	7배
cudaMemPrefetchAsync(CPU)	미지원	지원	—

WSL2가 미치는 영향

- Pageable D2H 비정상 감속:** Unified Memory의 D2H(GPU→CPU) 전송이 pinned 대비 4.5배 느림. 네이티브 Linux에서는 이 감속이 없음
- per-transfer 오버헤드:** 매 전송마다 0.36ms 고정 비용 → 레이어별 스와핑에서 수백 번 누적
- cudaMemPrefetchAsync(CPU) 미지원:** CUDA Managed Memory의 명시적 프리페치 API가 WSL2에서 동작하지 않음 → 프리페치 최적화 경로 차단

의미

- 현재 273.79초 중 일부는 WSL2 고유 오버헤드
- 네이티브 Linux로 전환 시 **약 40% 성능 개선** 예상 (특히 Pageable D2H 정상화)

- 단, WSL2의 pinned memory 대역폭은 네이티브와 유사하므로 pinned 기반 구현에서는 영향 적음
- **결론:** 최종 성능 평가는 네이티브 Linux에서 수행하는 것이 바람직하나, 최적화 방향성 (pinned + 비동기 + 레이어별) 탐색에는 WSL2에서도 유효

VRAM 점유 비율 분석

추론 시 VRAM 구성

분류	구성요소	크기	비율
정적 (모델 파라미터)	VLM Language Model	15.17 GB	63.7%
	Vision Encoder	1.15 GB	4.8%
	VLM LM Head	1.28 GB	5.4%
	Expert (Decoder)	4.56 GB	19.1%
동적 (추론 중)	KV Cache (~4,470 토큰)	0.56 GB	2.4%
	Activation + Overhead	1.10 GB	4.6%
합계		~23.82 GB	100%
측정 Peak		21.52 GB	

핵심 관찰

- **모델 파라미터가 93%** — VRAM의 대부분은 가중치가 차지
- **KV Cache는 2.4%** — GQA(Grouped Query Attention) 덕분에 KV Cache는 의외로 작음 (Full MHA 대비 1/4)
- **Activation은 4.6%** — SDPA(Scaled Dot-Product Attention) 적용으로 $O(n^2)$ 메모리 회피
- **VLM 단독 15.17GB > 12GB** → 모듈 스와핑만으로 해결 불가, 레이어 단위 스와핑 필수

시각화



